Aprendizado Não Supervisionado de Máquina

Fundamentos de Estatística Multivariada

Luiz Affonso Guedes - affonso@dca.ufrn.br

Só lembrando
- Você já fez a sua escolha.

Não se esqueça -

Ficar na superfície pode ser perigoso.

Então vamos um pouco mais fundo

A teoria vai te proteger, mas não seja imprudente!

Quiz Time

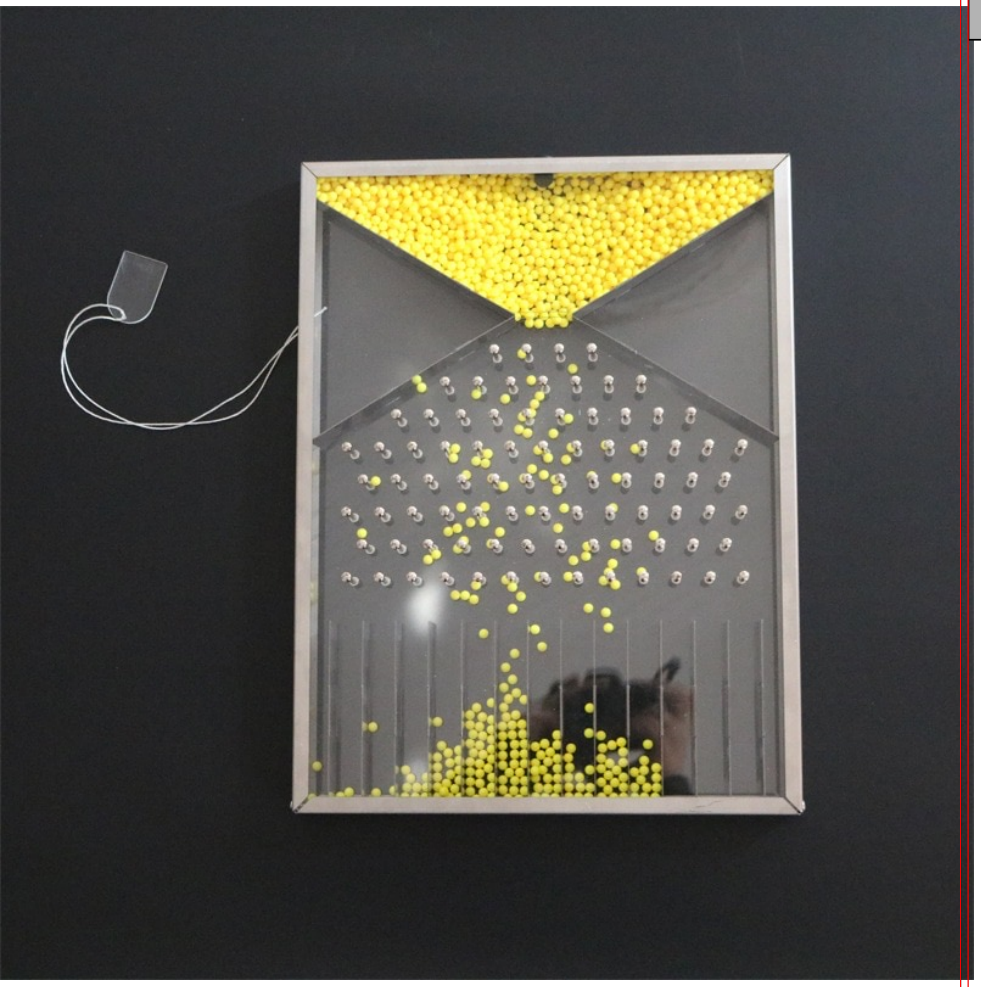

https://www.youtube.com/watch?v=4YTqDESTSdM

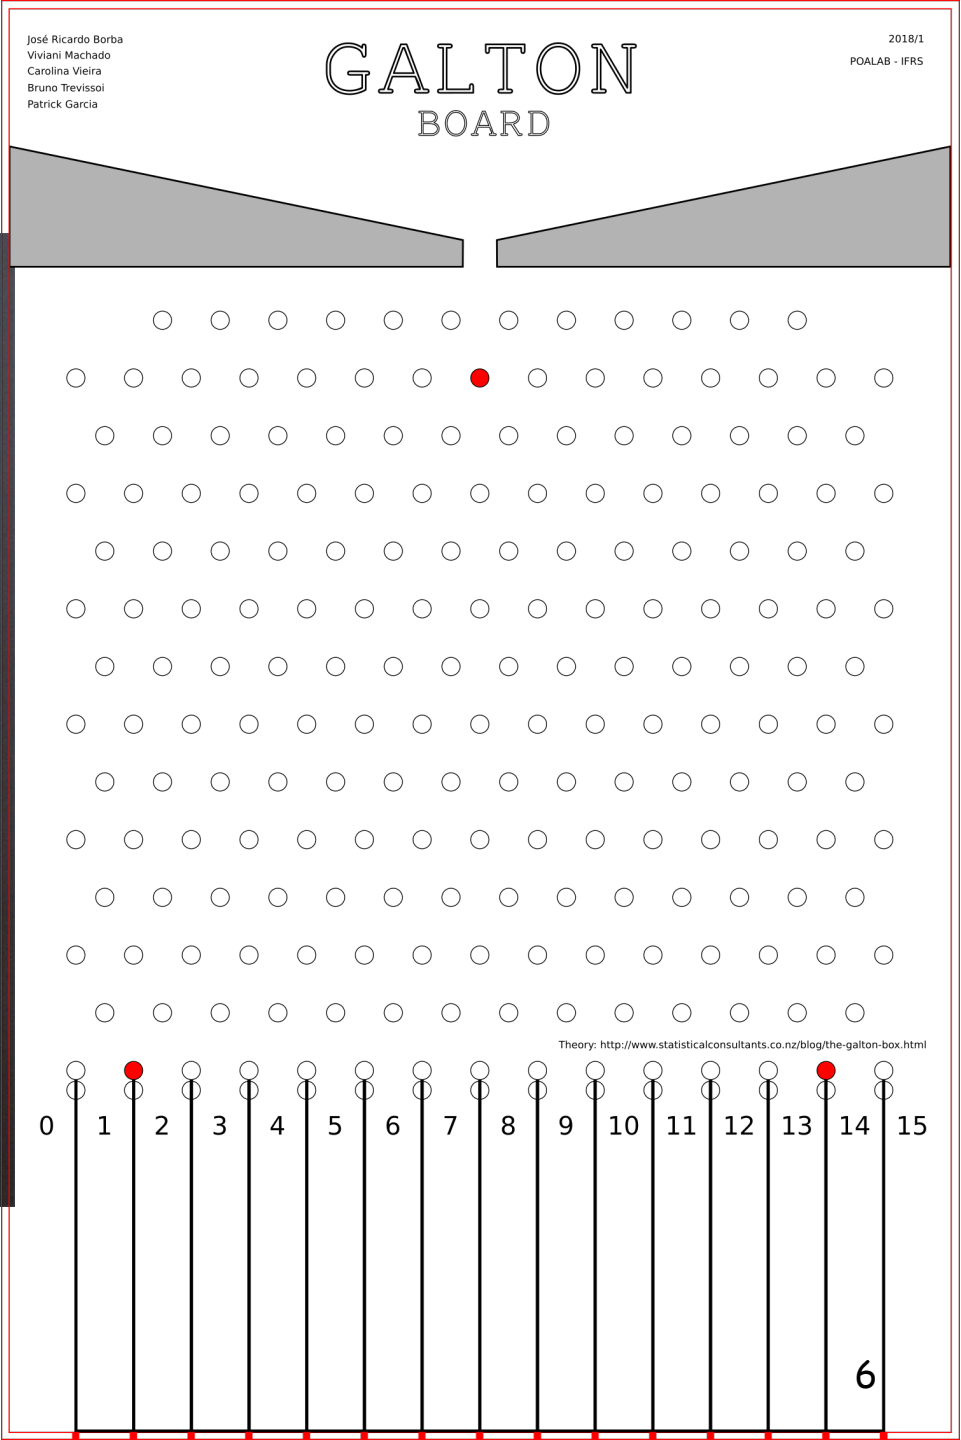

EU SOU NORMAL

Conteúdo

- Conceitos de estatística multivariada.
- Modelos estatísticos multivariados.
- Distribuições conjuntas, condicionais e marginais.
- Métricas de distância e similaridade.
- Estimadores de modelos estatísticos
  - KDE.

Referências para aula

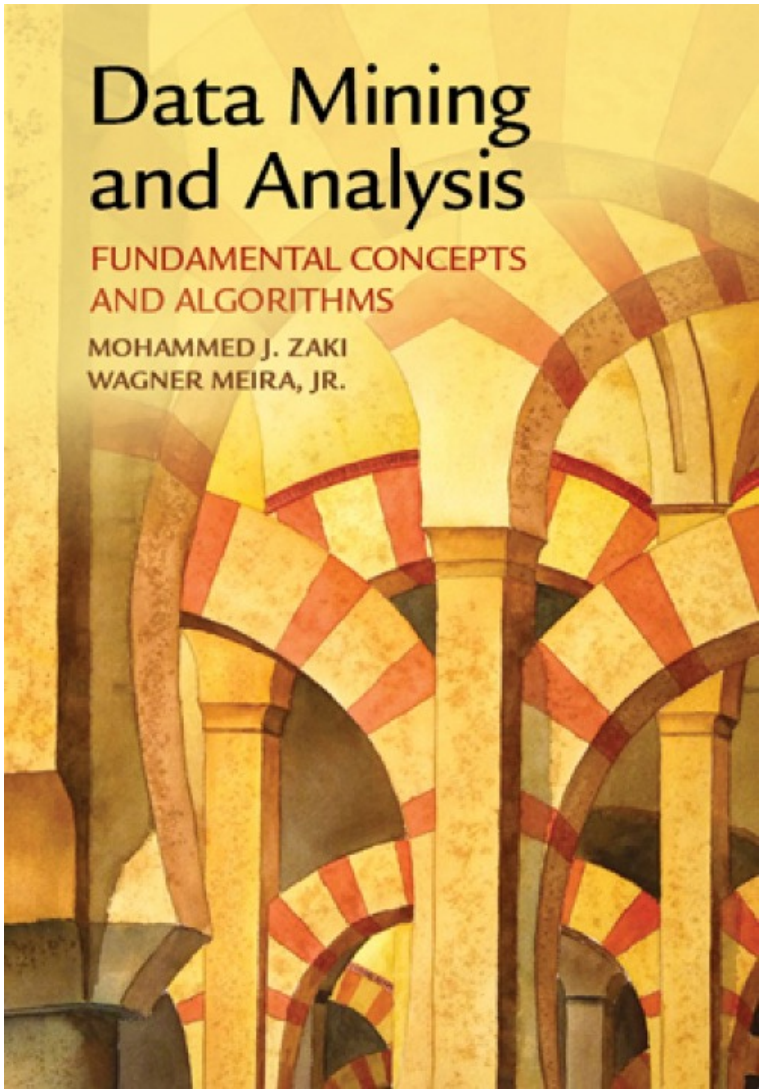

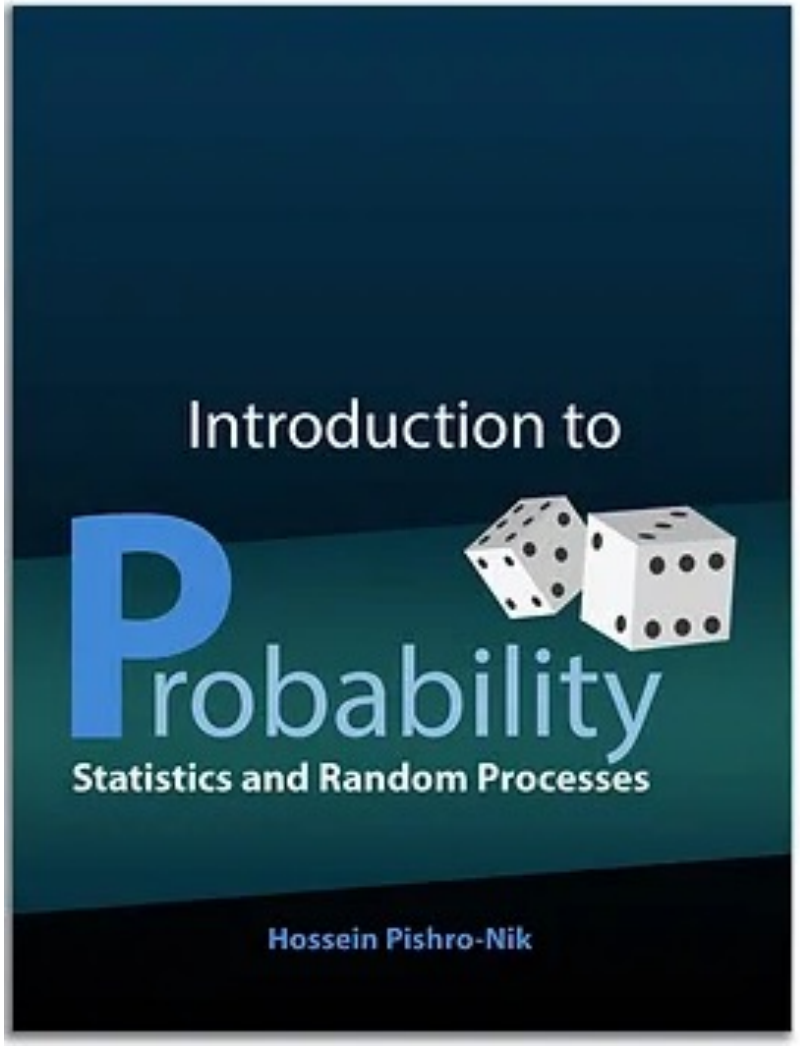

Variáveis Aleatórias Multidimensionais

- Uma V.A. X para o caso contínuo, é uma variável (domínio da função) pertencente aos reais.
- V.A. mapeia R^1 em R^1.

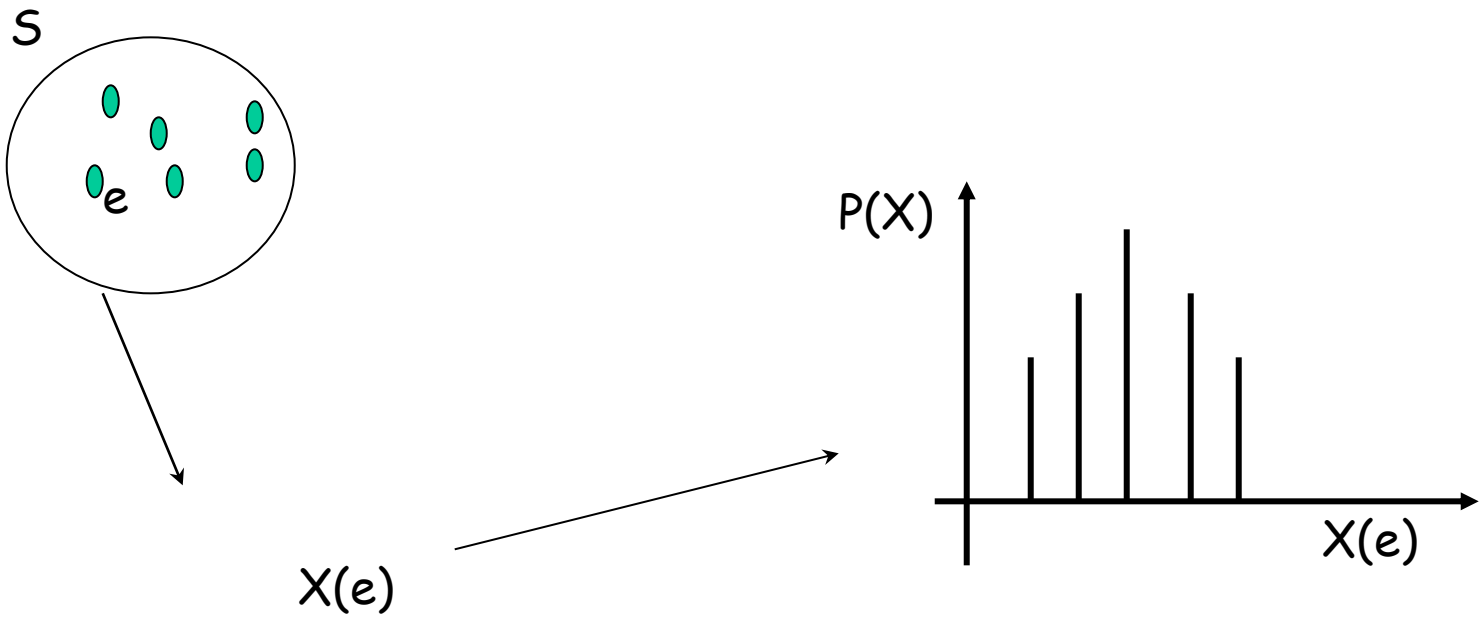

Variáveis Aleatórias Multidimensionais

- Para o caso multidimensional, temos que n V.A. (contínuas), são o domínio da função distribuição de probabilidade pertencente aos reais.
- V.A. multidimensional mapeia R^n em R^1.

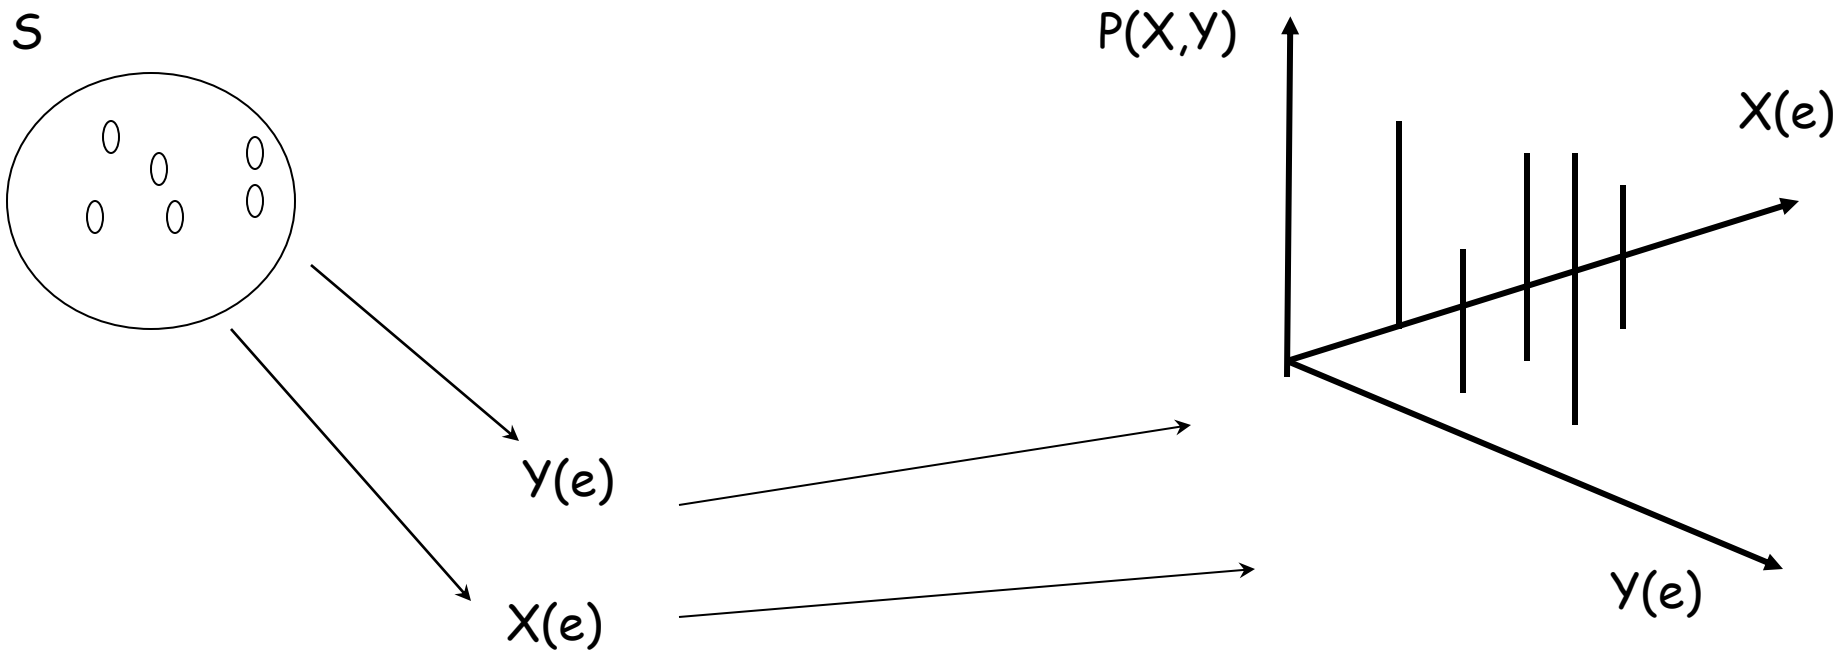

Variáveis Aleatórias Multidimensionais

- **Estatística Conjunta de V.A.:**
  - Interesse de se estudar simultaneamente várias características num determinado experimento.
  - Interesse de estudo da inter-relação dessas variáveis.
- **Definição:**
  - Sejam $X_1, X_2, \ldots, X_n$ V.A. definidas em S, um ponto nesse conjunto n-dimensional mapeia um único ponto no espaço unidimensional.
    - $0 \leq P(x1,x2, \ldots, xn) = k \leq 1$

Variáveis Aleatórias Multidimensionais

- Estatística Conjunta de V.A.:
  - Exemplos:
    - Numa pesquisa de opinião de votos, coleta-se além da intenção de voto, idade, sexo e renda: tridimensional f(Idade, Sexo, Renda).
    - Experimento de se lançar uma moeda (X) e um dado (Y) simultaneamente: bidimensional f(X,Y)
  - Deseja-se basicamente obter-se as inter-relações ou independências entre as diversas v.a. envolvidas no experimento.

Variáveis Aleatórias Multidimensionais

- Para o caso de V.A. discretas, temos uma tabela de n+1 colunas.

X_1	X_2	...	$P(X_1=x1, X_2=x2, ...)$
a1	b1		k1
a2	b2		k2
...	...	...	...

Exemplo

The Iris dataset

- Features:
  - Petal length
  - Petal width
  - Sepal length
  - Sepal width
- Target variable: Species
  - Versicolor
  - Virginica
  - Setosa

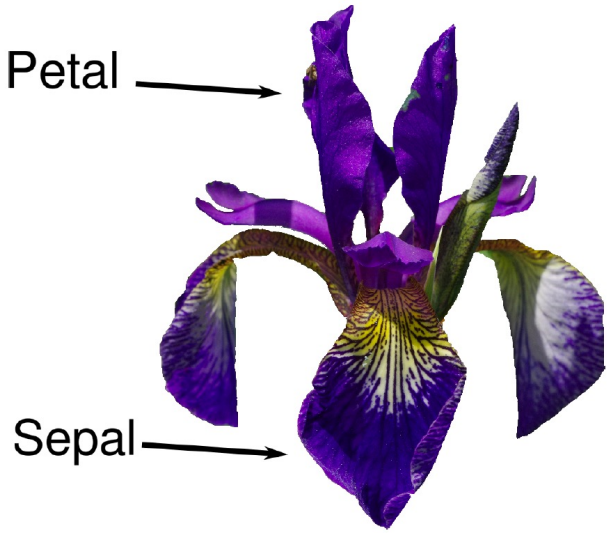

Tamanho (P)	Largura (P)	Tamanho (S)	Largura (S)	Espécie
5,1	3,5	1,4	0,2	Setosa
4,9	3,0	1,4	0,2	Setosa
7,0	3,2	4,7	1,4	Versicolor
6,4	3,2	4,5	1,5	Versicolor
6,3	3,3	6,0	2,5	Virgínica
5,8	2,7	5,1	1,9	Virgínica

Variáveis Aleatórias Multidimensionais

- Dados coletados multidimensionais

Table 1.1. Extract from the Iris dataset

	Sepal length X_1	Sepal width X_2	Petal length X_3	Petal width X_4	Class X_5
$\mathbf{x}_1$	5.9	3.0	4.2	1.5	Iris-versicolor
$\mathbf{x}_2$	6.9	3.1	4.9	1.5	Iris-versicolor
$\mathbf{x}_3$	6.6	2.9	4.6	1.3	Iris-versicolor
$\mathbf{x}_4$	4.6	3.2	1.4	0.2	Iris-setosa
$\mathbf{x}_5$	6.0	2.2	4.0	1.0	Iris-versicolor
$\mathbf{x}_6$	4.7	3.2	1.3	0.2	Iris-setosa
$\mathbf{x}_7$	6.5	3.0	5.8	2.2	Iris-virginica
$\mathbf{x}_8$	5.8	2.7	5.1	1.9	Iris-virginica
⋮	⋮	⋮	⋮	⋮	⋮
$\mathbf{x}_{149}$	7.7	3.8	6.7	2.2	Iris-virginica
$\mathbf{x}_{150}$	5.1	3.4	1.5	0.2	Iris-setosa

Variáveis Aleatórias Multidimensionais

- Para o caso de V.A. bidimensional:
  - $F_x(x) = P(X \leq x)$ ← Distribuição acumulativa em X
  - $F_y(y) = P(Y \leq y)$ ← Distribuição acumulativa em Y
  - $F_{x,y}(X,Y) = P(X \leq x; Y \leq y)$ ← Distribuição acumulativa conjunta
    - Probabilidade conjunta de X e Y.
  - $P(x_1 \leq X \leq x_2; y_1 \leq Y \leq y_2) = ?$

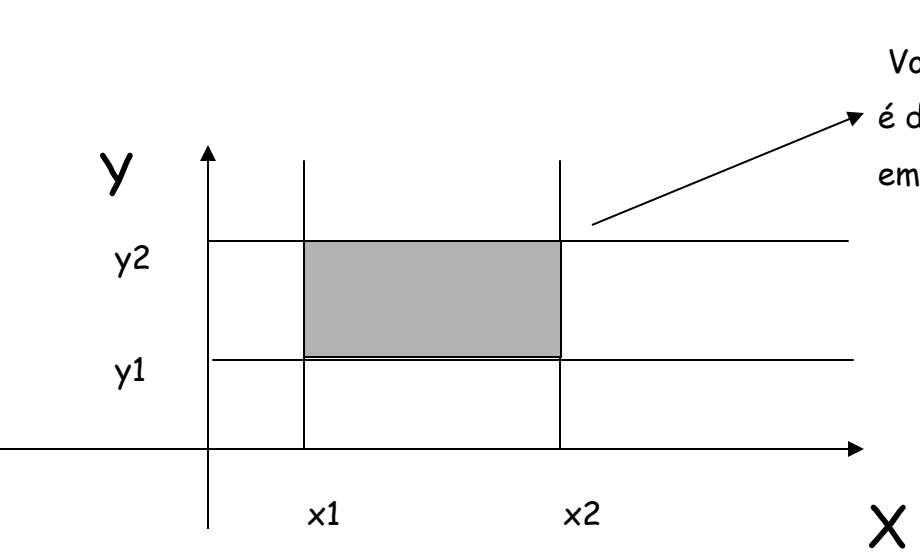

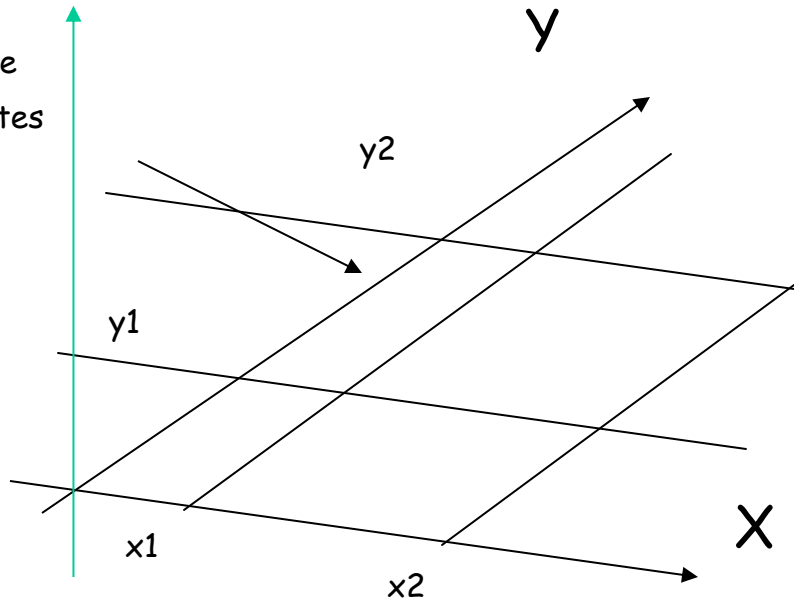

Variáveis Aleatórias Multidimensionais

- Para o caso de V.A. bidimensional:
  - Caso Discreto:
    - $F_{x,y}(x,y) = P(X \leq x;\ Y \leq y) = \Sigma_i \Sigma_j P(X=xi,\ Y=yj)$
  - Caso Contínuo:
    - $F_{x,y}(x,y) = P(X \leq x;\ Y \leq y) = \int_{-\infty,y} \int_{-\infty,x} f(x,y)\, dx\, dy$

Variáveis Aleatórias Multidimensionais

- Distribuições Marginais: projeção da função conjuntas.

$P(Y=y_j) = \Sigma_i P(X=x_i, Y=y_j)$

$f_x(x) = \int_{-\infty,+\infty} f_{xy}(x,y)\, dy$

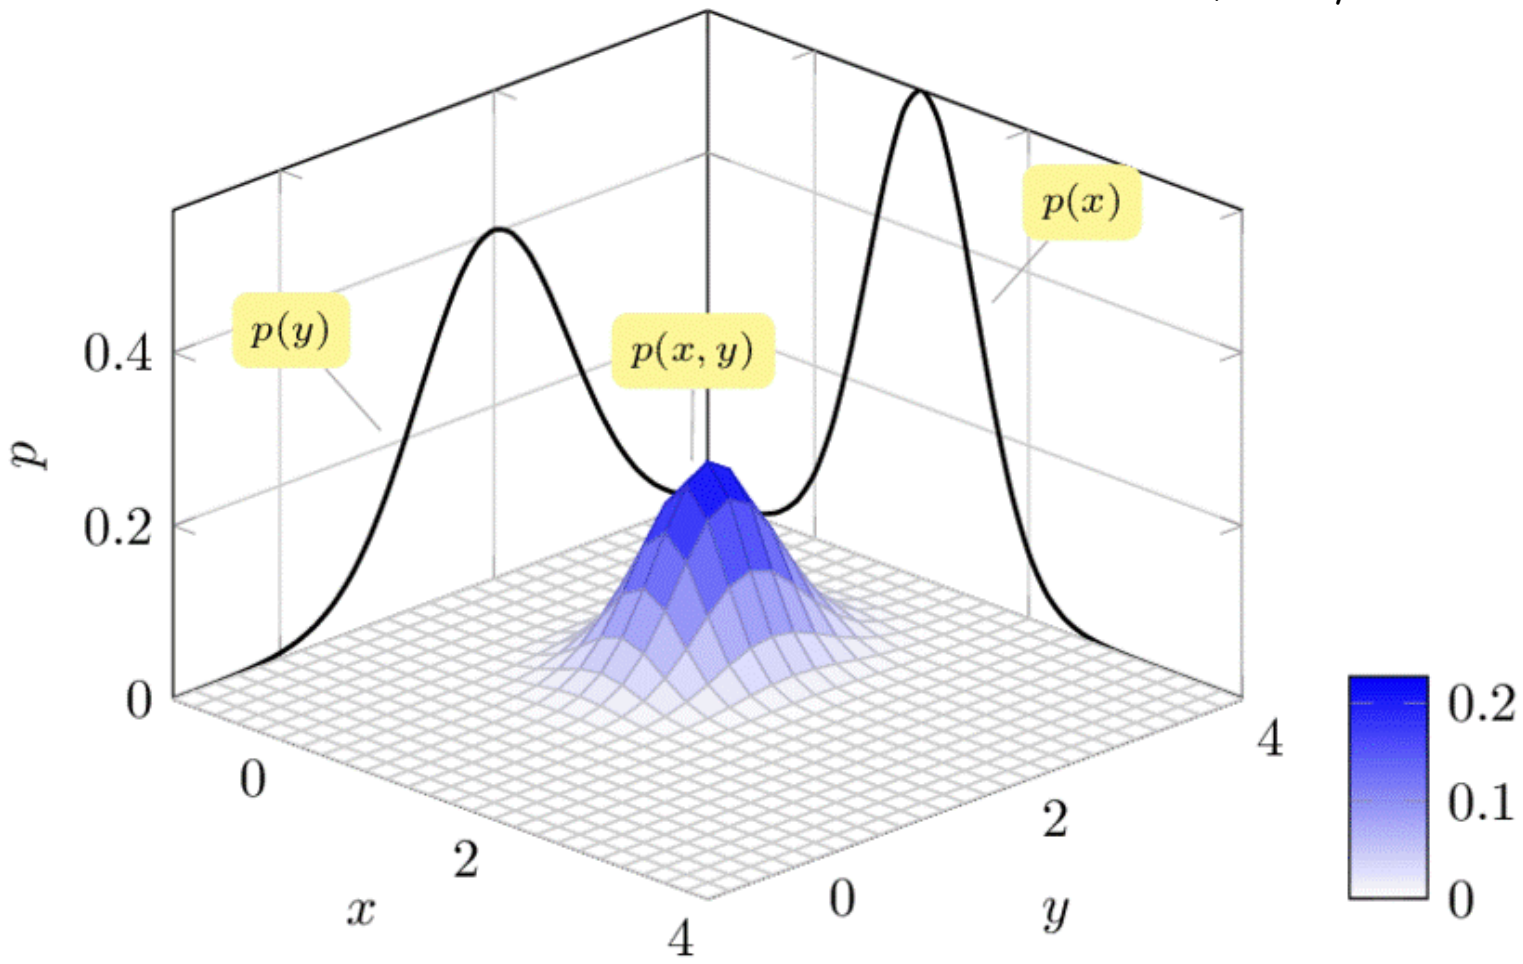

Variáveis Aleatórias Multidimensionais

- **Distribuições Marginais:**
  - **Caso n-dimensional:**
    - Dada $F(x_1,x_2,\ldots,x_n)$ calcular a distribuição marginal de X_1.
    - Caso discreto: $P(X_1 = x_1) = \Sigma_{x2}\ldots\Sigma_{xn}\, P(X_1=x_1, \ldots, X_n=x_n)$
    - Caso contínuo: $f_{x1}(x_1) = \int_{x2}\ldots\int_{xn} f(x_1,\ldots,x_n)\, dx_2\ldots dx_n$

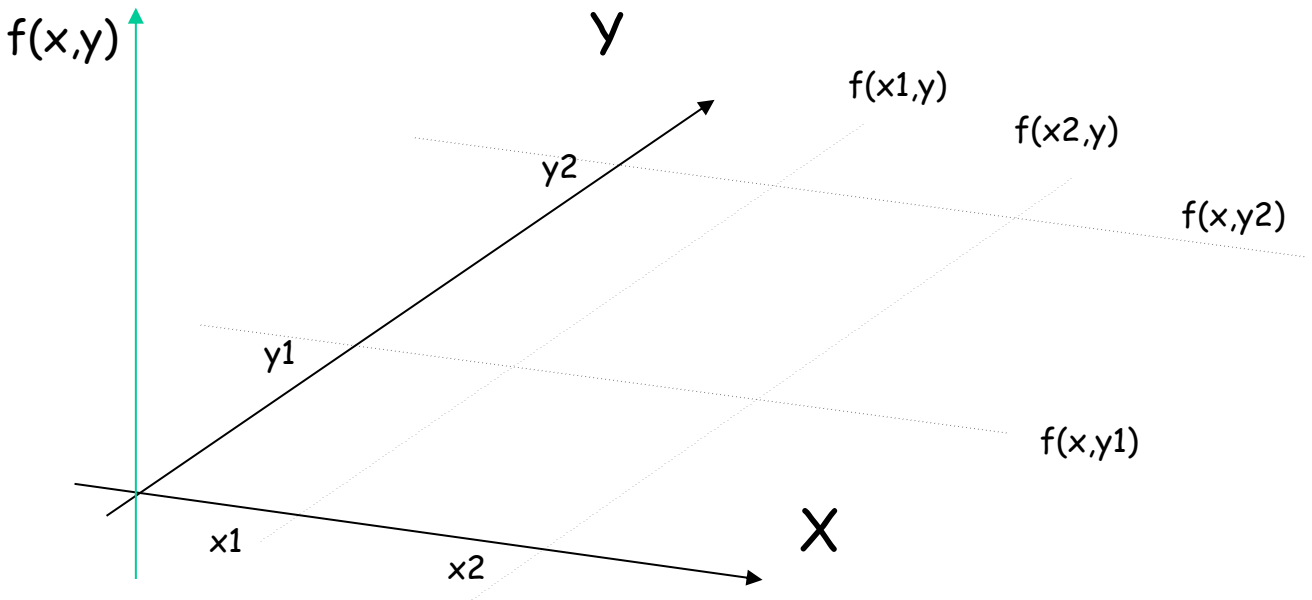

Variáveis Aleatórias Multidimensionais

- Distribuições Marginais:
  - Caso bidimensional: VAs X e Y
    - $F_{xy}(x,y) = \int_{-\infty,y} \int_{-\infty,x} f_{x,y}(x,y)\, dx\, dy$

Marginal PDFs

$$f_X(x) = \int_{-\infty}^{\infty} f_{XY}(x,y)dy, \quad \text{for all } x,$$

$$f_Y(y) = \int_{-\infty}^{\infty} f_{XY}(x,y)dx, \quad \text{for all } y.$$

- Independência:
  - $f_{x,y}(x,y) = f_{x,}(x) \,.\, f_y(y) \rightarrow F_{x,y}(x,y) = F_{x,}(x) \,.\, F_y(y)$

Variáveis Aleatórias Multidimensionais

- Distribuições Marginais:
  - Exemplo: Determine as distribuições marginais de X e Y.

	Y=1	Y=2	Y=3	Y=4	P(X)
X=1	0,10	0,05	0,02	0,07	
X=2	0,08	0,05	0,10	0,19	
X=3	0,10	0,20	0,04	0,00	
P(Y)					1

Variáveis Aleatórias Multidimensionais

- Distribuições Marginais:
  - Exemplo: dado 02 VAs X e Y com Função de Probabilidade Conjunta descrita por:

Table 5.1 Joint PMF of X and Y in Example 5.1

	$Y=0$	$Y=1$	$Y=2$
$X=0$	$\frac{1}{6}$	$\frac{1}{4}$	$\frac{1}{8}$
$X=1$	$\frac{1}{8}$	$\frac{1}{6}$	$\frac{1}{6}$

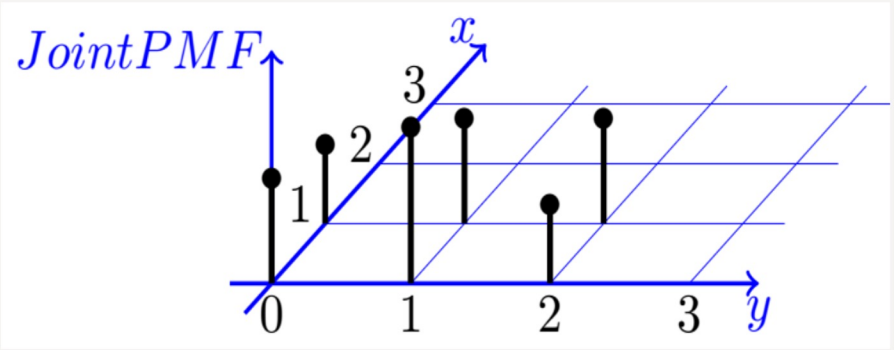

Figure 5.1: Joint PMF of X and Y (Example 5.1).

  - **Obter:**
    - P(X=0, Y<=1)
    - As marginais de X eY
    - P(Y=1/X=0)
    - X e Y são independentes? → P(Y=1/X=0) = P(Y=1) ?

$$P(Y=1|X=0) = \frac{P(X=0,Y=1)}{P(X=0)} = \frac{P_{XY}(0,1)}{P_X(0)} = \frac{\frac{1}{4}}{\frac{13}{24}} = \frac{6}{13}.$$

Variáveis Aleatórias Multidimensionais

- Distribuições Acumulativas Conjuntas:

$$F_{XY}(x,y) = P(X \le x, Y \le y)$$
$$= P\Big((X \le x) \text{ and } (Y \le y)\Big) = P\Big((X \le x) \cap (Y \le y)\Big).$$

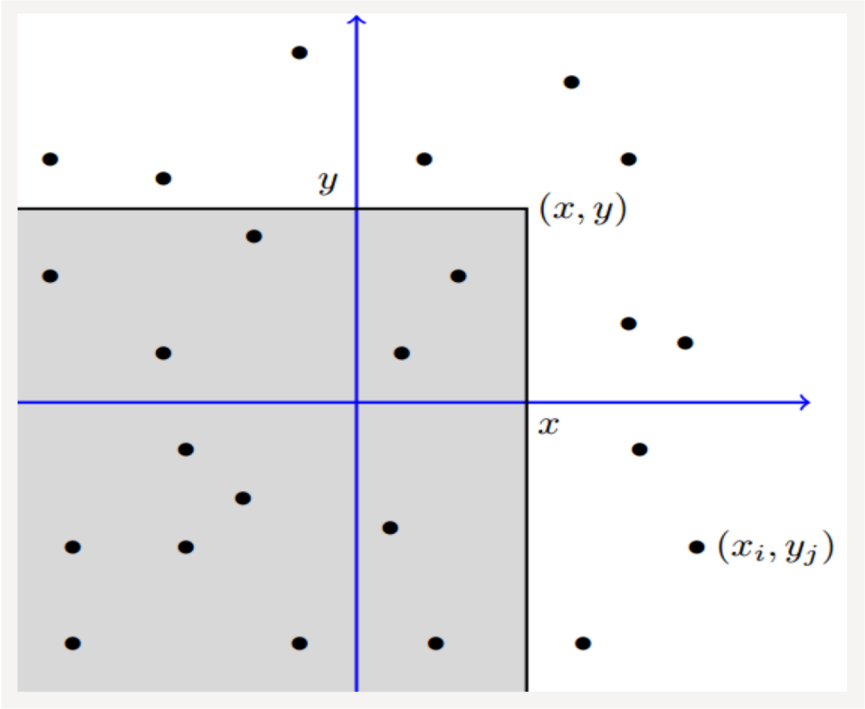

Variáveis Aleatórias Multidimensionais

- Distribuições Acumulativas Conjuntas:
  - Propriedades:

The **joint cumulative function** of two random variables X and Y is defined as

$$F_{XY}(x, y) = P(X \leq x, Y \leq y).$$

The joint CDF satisfies the following properties:

1. $F_X(x) = F_{XY}(x, \infty)$, for any x (marginal CDF of X);
2. $F_Y(y) = F_{XY}(\infty, y)$, for any y (marginal CDF of Y);
3. $F_{XY}(\infty, \infty) = 1$;
4. $F_{XY}(-\infty, y) = F_{XY}(x, -\infty) = 0$;
5. $P(x_1 < X \leq x_2, \;\; y_1 < Y \leq y_2) =$
$$F_{XY}(x_2, y_2) - F_{XY}(x_1, y_2) - F_{XY}(x_2, y_1) + F_{XY}(x_1, y_1);$$
6. if X and Y are independent, then $F_{XY}(x, y) = F_X(x)F_Y(y)$.

Variáveis Aleatórias Multidimensionais

- Função Densidade de Probabilidade Conjunta
  - $f_{xy}(x,y) = \partial^2 F_{x,y}(x,y)/\partial x\, \partial y$
  - $\partial F_{x,y}(x,y)/\partial dx = \int_{-\infty,y} f_{x,y}(x,v)dv$
  - $f_{x1,\ldots,xn}(x_1,\ldots, x_n) = \partial^n F_{x1\ldots,xn}(x_1,\ldots, x_n)/\partial x_1 \ldots \partial x_n$

Variáveis Aleatórias Multidimensionais

- V.A. Independentes:

  As V.A. $X_1, \ldots, X_n$ são ditas independentes se para todos os seus valores tivermos:

  - $P[X_1=x1, \ldots, X_n=xn] = P[X_1=x1] \ldots P[X_n=xn]$

  - Se as V.A. são independentes, então a distribuição conjunta é dada pelo produto das distribuições marginais.

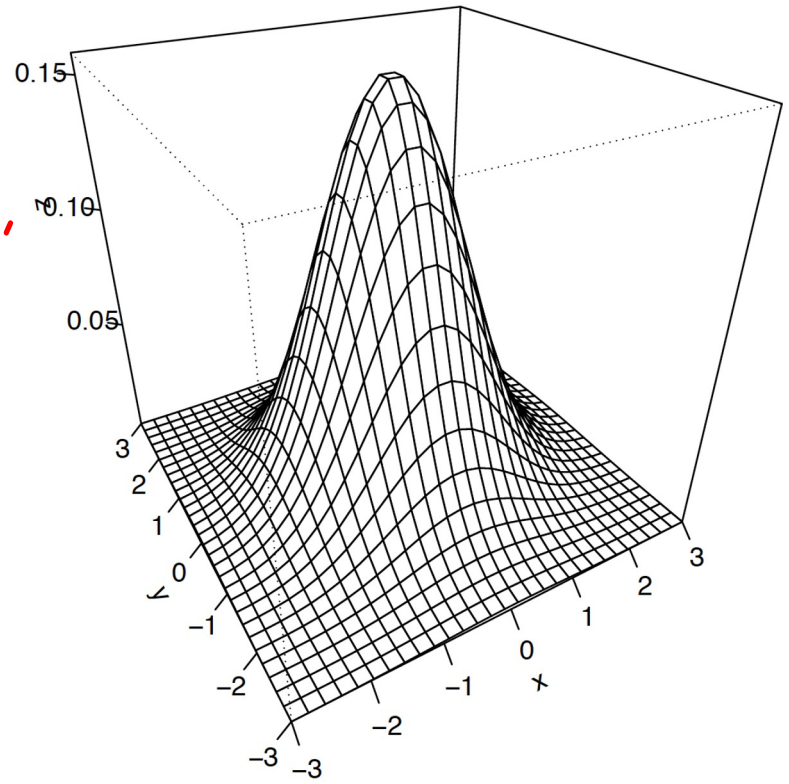

Variáveis Aleatórias Multidimensionais

- V.A. Independentes:

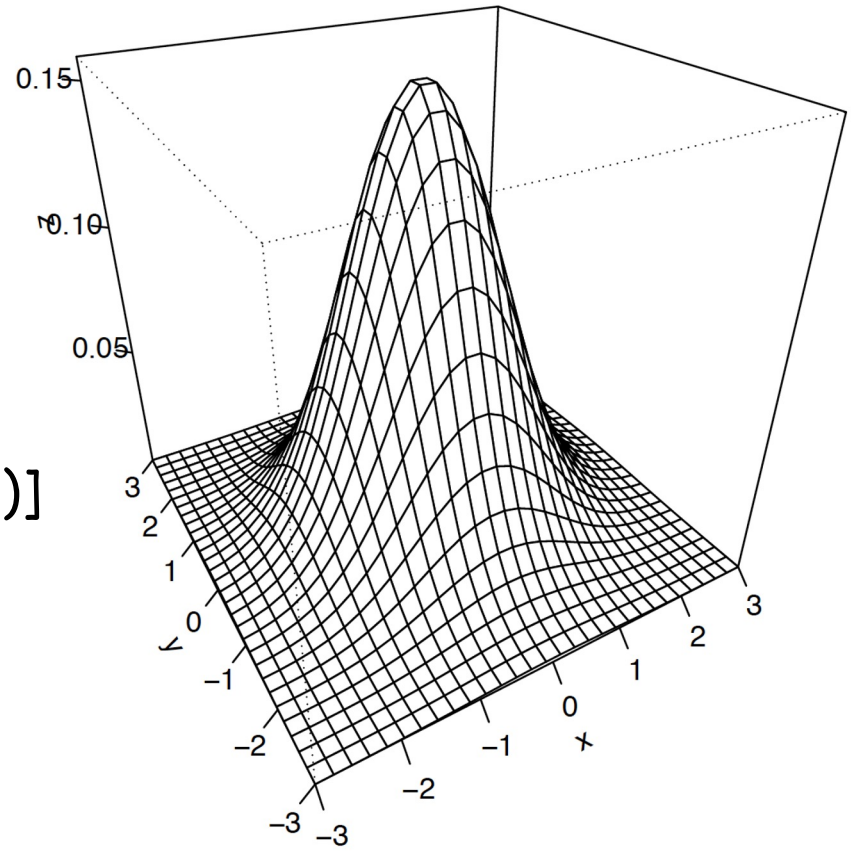

- Consequências:
  - $F_{x,y}(x,y) = F_x(x) \cdot F_y(y)$
  - $f_{x,y}(x,y) = f_x(x) \cdot f_y(y)$
  - $E[XY] = E[X]\,E[Y]$
  - $E[g(X).h(Y)] = E[g(X)].\ E[h(Y)]$
  - $Var(X+Y) = Var(X) + Var(Y)$

  - $f_{x,y}(x,y) = f_{x,}(x) \cdot f_{,y}(y) \rightarrow F_{x,y}(x,y) = F_{x,}(x) \cdot F_y(y)$

Variáveis Aleatórias Multidimensionais

- Probabilidades Condicionais

$$P(X \in C | Y \in D) = \frac{P(X \in C, Y \in D)}{P(Y \in D)}, \text{ where } C, D \subset \mathbb{R}.$$

  - Condicional em relação a um evento A

For a discrete random variable X and event A, the **conditional PMF** of X given A is defined as

$$\begin{aligned} P_{X|A}(x_i) &= P(X = x_i | A) \\ &= \frac{P(X = x_i \text{ and } A)}{P(A)}, \quad \text{for any } x_i \in R_X. \end{aligned}$$

Similarly, we define the **conditional CDF** of X given A as

$$F_{X|A}(x) = P(X \leq x | A).$$

Variáveis Aleatórias Multidimensionais

- Probabilidades Condicionais
  - Exemplo: Considerando-se um dado honesto, determine a função de distribuição de probabilidade condicional de X, dado que o valor observado é menor que 5. (X é a VA- número da face do dado)
  - Evento $A=\{X<5\}$
  - $P(A) = 4/6$
  - $P_{X/A}(i) = P(X=i/X<5) = P(X=i \text{ AND } X<5)/P(X<5)$

Variáveis Aleatórias Multidimensionais

- Probabilidades Condicionais entre duas VAs X e Y:

For discrete random variables X and Y, the **conditional PMFs** of X given Y and vice versa are defined as

$$P_{X|Y}(x_i|y_j) = \frac{P_{XY}(x_i, y_j)}{P_Y(y_j)},$$

$$P_{Y|X}(y_j|x_i) = \frac{P_{XY}(x_i, y_j)}{P_X(x_i)}$$

for any $x_i \in R_X$ and $y_j \in R_Y$.

Variáveis Aleatórias Multidimensionais

- Probabilidades Condicionais entre duas VAs X e Y:

$$f_{X|Y}(x|y) = \frac{f_{XY}(x,y)}{f_Y(y)}$$

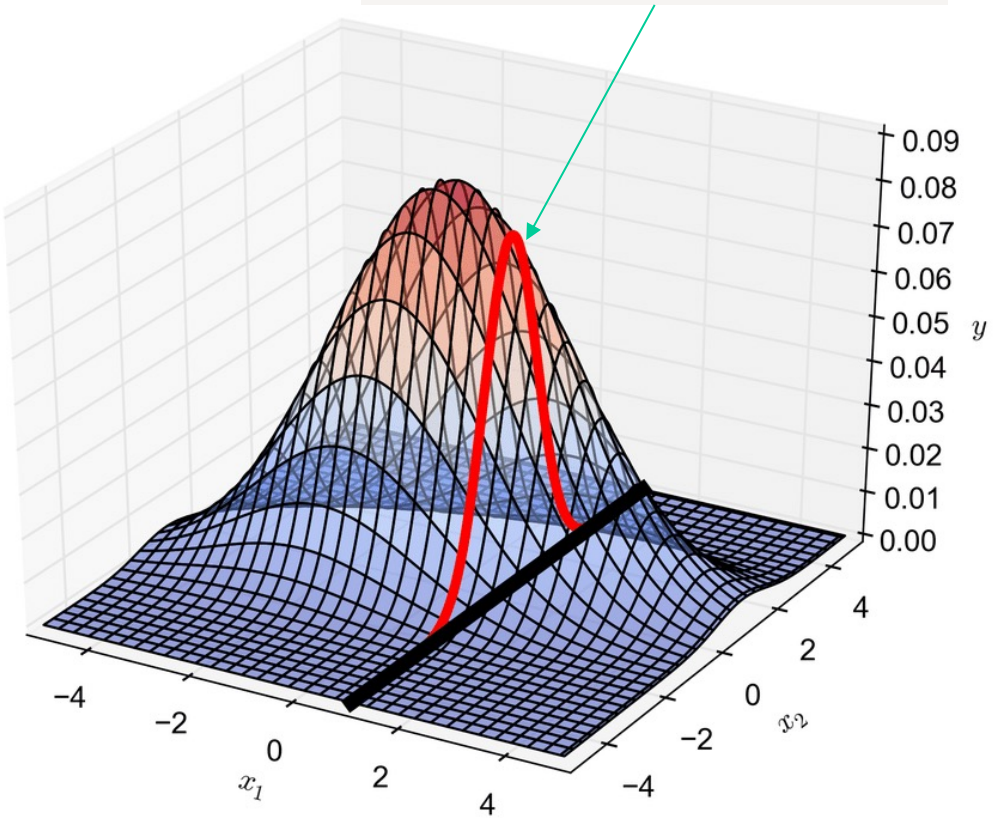

Variáveis Aleatórias Multidimensionais

- Probabilidades Condicionais entre duas VAs X e Y:

For two jointly continuous random variables X and Y, we can define the following conditional concepts:

1. The conditional PDF of X given $Y = y$:

$$f_{X|Y}(x|y) = \frac{f_{XY}(x,y)}{f_Y(y)}$$

2. The conditional probability that $X \in A$ given $Y = y$:

$$P(X \in A|Y = y) = \int_A f_{X|Y}(x|y)dx$$

3. The conditional CDF of X given $Y = y$:

$$F_{X|Y}(x|y) = P(X \leq x|Y = y) = \int_{-\infty}^{x} f_{X|Y}(x|y)dx$$

Variáveis Aleatórias Multidimensionais

Independência entre VAs

Two discrete random variables X and Y are independent if

$$P_{XY}(x, y) = P_X(x)P_Y(y), \qquad \text{for all } x, y.$$

Equivalently, X and Y are independent if

$$F_{XY}(x, y) = F_X(x)F_Y(y), \qquad \text{for all } x, y.$$

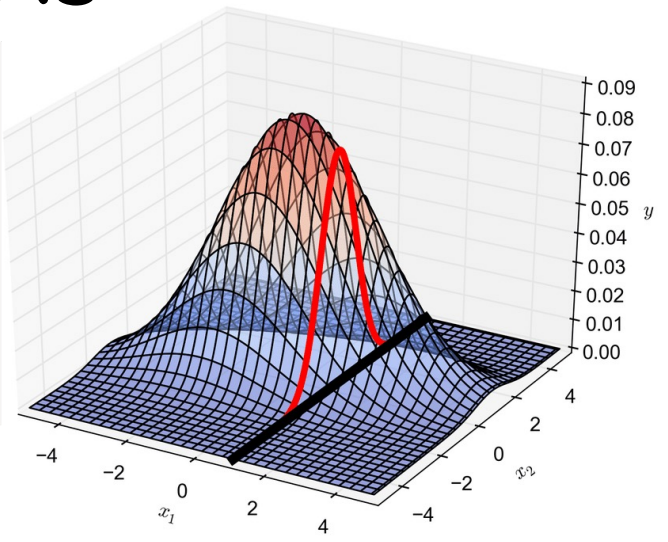

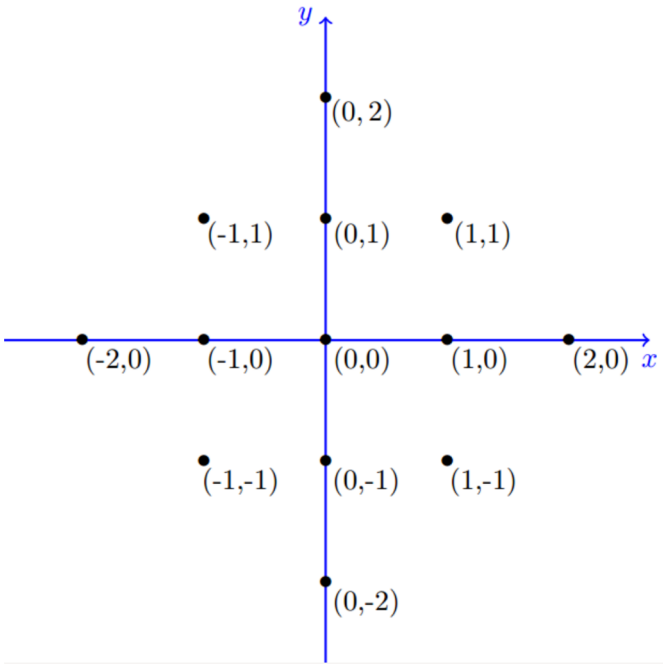

$$\begin{aligned} P_{X|Y}(x_i|y_j) &= P(X = x_i|Y = y_j) \\ &= \frac{P_{XY}(x_i, y_j)}{P_Y(y_j)} \\ &= \frac{P_X(x_i)P_Y(y_j)}{P_Y(y_j)} \\ &= P_X(x_i). \end{aligned}$$

Variáveis Aleatórias Multidimensionais

- Esperança Condicional: caso discreto

Conditional Expectation of X:

$$E[X|A] = \sum_{x_i \in R_X} x_i P_{X|A}(x_i),$$

$$E[X|Y = y_j] = \sum_{x_i \in R_X} x_i P_{X|Y}(x_i|y_j)$$

Variáveis Aleatórias Multidimensionais

- Esperança e Variância Condicionais: caso contínuo

For two jointly continuous random variables X and Y, we have:

1. Expected value of X given $Y = y$:

$$E[X|Y = y] = \int_{-\infty}^{\infty} x f_{X|Y}(x|y)dx$$

2. Conditional LOTUS:

$$E[g(X)|Y = y] = \int_{-\infty}^{\infty} g(x) f_{X|Y}(x|y)dx$$

3. Conditional variance of X given $Y = y$:

$$Var(X|Y = y) = E[X^2|Y = y] - (E[X|Y = y])^2$$

Variáveis Aleatórias Multidimensionais

- Caso de VAs Discretas:

Law of Total Probability:

$$P(X \in A) = \sum_{y_j \in R_Y} P(X \in A | Y = y_j) P_Y(y_j), \quad \text{for any set } A.$$

Law of Total Expectation:

1. If $B_1, B_2, B_3, \ldots$ is a partition of the sample space S,

$$EX = \sum_i E[X|B_i]P(B_i) \tag{5.3}$$

2. For a random variable X and a discrete random variable Y,

$$EX = \sum_{y_j \in R_Y} E[X|Y = y_j]P_Y(y_j) \tag{5.4}$$

Variáveis Aleatórias Multidimensionais

- Caso de VAs Contínuas:

Law of Total Probability:

$$P(A) = \int_{-\infty}^{\infty} P(A|X = x) f_X(x)\ dx \qquad (5.16)$$

Law of Total Expectation:

$$E[Y] = \int_{-\infty}^{\infty} E[Y|X = x] f_X(x)\ dx \qquad (5.17)$$
$$= E[E[Y|X]]$$

Law of Total Variance:

$$\text{Var}(Y) = E[\text{Var}(Y|X)] + \text{Var}(E[Y|X]) \qquad (5.18)$$

Variáveis Aleatórias Multidimensionais

- Soma de VAs independentes:

If X and Y are two jointly continuous random variables and $Z = X + Y$, then

$$f_Z(z) = \int_{-\infty}^{\infty} f_{XY}(w, z - w)dw = \int_{-\infty}^{\infty} f_{XY}(z - w, w)dw.$$

If X and Y are also independent, then

$$\begin{aligned} f_Z(z) &= f_X(z) * f_Y(z) \\ &= \int_{-\infty}^{\infty} f_X(w) f_Y(z - w)dw = \int_{-\infty}^{\infty} f_Y(w) f_X(z - w)dw. \end{aligned}$$

Variáveis Aleatórias Multidimensionais

- Soma de VAs independentes:
  - Exemplo: soma de 02 VAs normais resulta numa VA normal.

Example 5.31

Let X and Y be two independent standard normal random variables, and let $Z = X + Y$. Find the PDF of Z.

Solution

We have

$$\begin{aligned} f_Z(z) &= f_X(z) * f_Y(z) \\ &= \int_{-\infty}^{\infty} f_X(w) f_Y(z-w) dw \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi} e^{-\frac{w^2}{2}} e^{-\frac{(z-w)^2}{2}} dw \\ &= \frac{1}{\sqrt{4\pi}} e^{\frac{-z^2}{4}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{\pi}} e^{-(w-\frac{z}{2})^2} dw \\ &= \frac{1}{\sqrt{4\pi}} e^{\frac{-z^2}{4}}, \end{aligned}$$

where $\int_{-\infty}^{\infty} \frac{1}{\sqrt{\pi}} e^{-(w-\frac{z}{2})^2} dw = 1$ because it is the integral of the PDF of a normal random variable with mean $\frac{z}{2}$ and variance $\frac{1}{2}$. Thus, we conclude that $Z \sim N(0, 2)$. In fact, this is one of the interesting properties of the normal distribution: the sum of two independent normal random variables is also normal. In particular, similar to our calculation above, we can show the following:

Variáveis Aleatórias Multidimensionais

- Soma de VAs independentes:
  - Soma de 02 VAs normais independentes resulta numa VA normal.

Theorem 5.2
If $X \sim N(\mu_X, \sigma_X^2)$ and $Y \sim N(\mu_Y, \sigma_Y^2)$ are independent, then

$$X + Y \sim N\left(\mu_X + \mu_Y, \sigma_X^2 + \sigma_Y^2\right).$$

Variáveis Aleatórias Multidimensionais

- Covariância
  - Sejam as v.a. X e Y. As suas variâncias fornecem uma medida de dispersão em relação às suas médias.
  - A covariância fornece uma medida de dispersão de uma v.a. bidimensional em relação ao ponto (E[X], E[Y]).
  - $Cov(X,Y) = E\{ (X-E[X]) (Y-E[Y]) \}$

Variáveis Aleatórias Multidimensionais

- Covariância

The **covariance** between X and Y is defined as

$$\mathrm{Cov}(X, Y) = E\big[(X - EX)(Y - EY)\big] = E[XY] - (EX)(EY).$$

Variáveis Aleatórias Multidimensionais

- Covariância
  - $Cov(X,Y) = E\{ (X-E[X]) (Y-E[Y]) \}$
  - $Cov(X,Y) = \Sigma_i \Sigma_j (x_i-m_x) (y_i-m_y) P(X=x_i, Y=y_j)$
  - $Cov(X,Y) = \int_y \int_x (x_i-m_x) (y_i-m_y) f(x,y)\, dx\, dy$
  - $Cov(X,Y) = E[XY] - E[X]\, E[Y]$
  - $C_{x,y} = R_{x,y} - m_x.m_y$;
  - $R_{x,y} = \int_y \int_x x_i\, y_i\, f(x,y)\, dx\, dy$ ←Correlação
  - $C_{x,y} = \frac{\sum_{i=1}^{n} (xi-mx)(yi-my)}{n}$

Variáveis Aleatórias Multidimensionais

- ## Covariância: Propriedades

Lemma 5.3
The covariance has the following properties:

1. $\mathrm{Cov}(X, X) = \mathrm{Var}(X)$;
2. if X and Y are independent then $\mathrm{Cov}(X, Y) = 0$;
3. $\mathrm{Cov}(X, Y) = \mathrm{Cov}(Y, X)$;
4. $\mathrm{Cov}(aX, Y) = a\mathrm{Cov}(X, Y)$;
5. $\mathrm{Cov}(X + c, Y) = \mathrm{Cov}(X, Y)$;
6. $\mathrm{Cov}(X + Y, Z) = \mathrm{Cov}(X, Z) + \mathrm{Cov}(Y, Z)$;
7. more generally,

$$\mathrm{Cov}\left(\sum_{i=1}^{m} a_i X_i, \sum_{j=1}^{n} b_j Y_j\right) = \sum_{i=1}^{m}\sum_{j=1}^{n} a_i b_j \mathrm{Cov}(X_i, Y_j).$$

$$\begin{aligned}\mathrm{Cov}(X + Y, Z) &= E[(X + Y)Z] - E(X + Y)EZ \\ &= E[XZ + YZ] - (EX + EY)EZ \\ &= EXZ - EXEZ + EYZ - EYEZ \\ &= \mathrm{Cov}(X, Z) + \mathrm{Cov}(Y, Z).\end{aligned}$$

$$\mathrm{Cov}(X, Y) = E[XY] - EXEY = 0.$$

Variáveis Aleatórias Multidimensionais

- Covariância: Exemplo

Example 5.33

Let X and Y be two independent $N(0, 1)$ random variables and

$$Z = 1 + X + XY^2,$$
$$W = 1 + X.$$

Find $\mathrm{Cov}(Z, W)$.

Solution

$$\begin{aligned}
\mathrm{Cov}(Z, W) &= \mathrm{Cov}(1 + X + XY^2, 1 + X) \\
&= \mathrm{Cov}(X + XY^2, X) && \text{(by part 5 of Lemma 5.3)} \\
&= \mathrm{Cov}(X, X) + \mathrm{Cov}(XY^2, X) && \text{(by part 6 of Lemma 5.3)} \\
&= \mathrm{Var}(X) + E[X^2Y^2] - E[XY^2]EX && \text{(by part 1 of Lemma 5.3 \& definition of Cov)} \\
&= 1 + E[X^2]E[Y^2] - E[X]^2E[Y^2] && \text{(since } X \text{ and } Y \text{ are independent)} \\
&= 1 + 1 - 0 = 2.
\end{aligned}$$

Variáveis Aleatórias Multidimensionais

- Variância da Soma de 02 VAs
  - Z = X+Y

$$\begin{aligned}\mathrm{Var}(Z) &= \mathrm{Cov}(Z, Z) \\ &= \mathrm{Cov}(X + Y, X + Y) \\ &= \mathrm{Cov}(X, X) + \mathrm{Cov}(X, Y) + \mathrm{Cov}(Y, X) + \mathrm{Cov}(Y, Y) \\ &= \mathrm{Var}(X) + \mathrm{Var}(Y) + 2\mathrm{Cov}(X, Y).\end{aligned}$$

  - Para o caso geral:

$$\mathrm{Var}(aX + bY) = a^2\mathrm{Var}(X) + b^2\mathrm{Var}(Y) + 2ab\mathrm{Cov}(X, Y) \qquad (5.21)$$

Variáveis Aleatórias Multidimensionais

- Covariância
  - Consequências:
    - $Var(X+Y) = Var(X) + Var(Y) + 2Cov(X,Y)$
    - Se X e Y são independente → $Cov(X,Y) = 0$
    - Se X e Y tendem a variar no mesmo sentido, a Cov(X,Y) será positiva.
    - Se X e Y tendem a variar em sentidos opostos, a Cov(X,Y) será negativa.

Variáveis Aleatórias Multidimensionais

- Covariância e Coeficiente de Correlação
  - Sejam duas VAs X e Y. Se X'= aX e Y'= bY:
    - Cov(X',Y') = ab Cov(X,Y)
    - $\mathrm{Cov}(X,Y) = E[XY] - E[X]\,E[Y]$
    - Então, a covariância depende das escalas das VAs.
- Seria interessante se trabalhar com uma medida de dispersão independente de escala!

Variáveis Aleatórias Multidimensionais

- Coeficiente de Correlação
  - $\rho(X,Y) = Cov(X,Y) / (\sigma(X) \sigma(Y))$
  - $| \rho(X,Y) | \leq 1$ ← normalização da covariância
  - Se $X' = aX$ e $Y' = bY$:
    - $Cov(X',Y') = ab\ Cov(X,Y)$
    - $\rho(X',Y') = ab\ Cov(X,Y) / (a\ \sigma(X)\ b\sigma(Y))$
    - $= \rho(X,Y)$
  - Se $Y = aX + b \rightarrow \rho(X,Y) = signal(a) \cdot 1$

Variáveis Aleatórias Multidimensionais

- Coeficiente de Correlação
  - - Propriedades

Properties of the correlation coefficient:

1. $-1 \leq \rho(X, Y) \leq 1$;
2. if $\rho(X, Y) = 1$, then $Y = aX + b$, where $a > 0$;
3. if $\rho(X, Y) = -1$, then $Y = aX + b$, where $a < 0$;
4. $\rho(aX + b, cY + d) = \rho(X, Y)$ for $a, c > 0$.

Variáveis Aleatórias Multidimensionais

- Coeficiente de Correlação

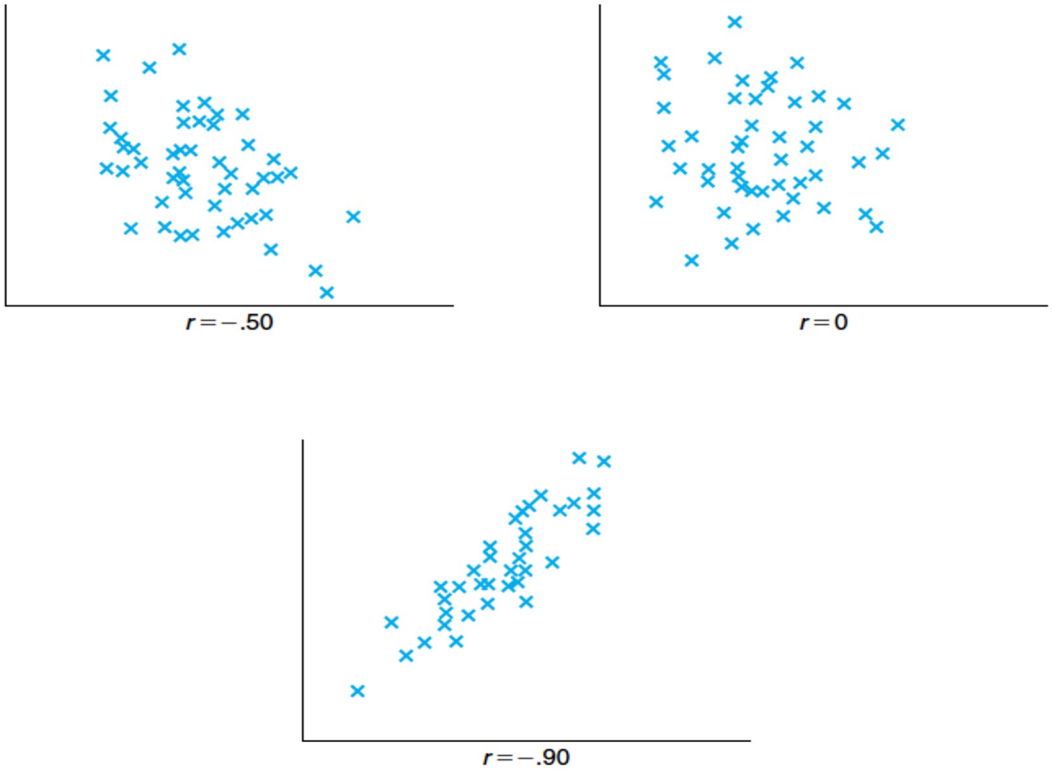

FIGURE 2.14 *Sample correlation coefficients.*

Variáveis Aleatórias Multidimensionais

- Descorrelação
  - $Cov(X,Y) = C_{x,y} = 0 \rightarrow \rho(X,Y) = 0$;
    - $\mathrm{Cov}(X,Y) = E[XY] - E[X]\,E[Y]$
  - $E[XY] = E[X]\,E[Y]$ ← independência implica em descorrelação, mas o inverso não é verdadeiro.
  - $Var(X+Y) = Var(X) + Var(Y) + 2.Cov(X,Y)$
    - Basta ser descorrelacionado, não necessariamente independente.
- Ortogonalidade:
  - $E[XY] = 0$ ← X e Y são ortogonais.

Variáveis Aleatórias Multidimensionais

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ \cdot \\ \cdot \\ \cdot \\ X_n \end{bmatrix}.$$

$$E\mathbf{X} = \begin{bmatrix} EX_1 \\ EX_2 \\ \cdot \\ \cdot \\ \cdot \\ EX_n \end{bmatrix}.$$

$$\mathbf{Y} = \mathbf{AX} + \mathbf{b},$$

$$E\mathbf{Y} = \mathbf{AEX} + \mathbf{b}.$$

$$\mathbf{E[X_1 + X_2 + \cdots + X_k] = EX_1 + EX_2 + \cdots + EX_k}.$$

Variáveis Aleatórias Multidimensionais

Matriz de Correlação

$$\mathbf{R_X} = \mathbf{E}[\mathbf{X}\mathbf{X}^{\mathbf{T}}] = E\begin{bmatrix} X_1^2 & X_1X_2 & \dots & X_1X_n \\ X_2X_1 & X_2^2 & \dots & X_2X_n \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ X_nX_1 & X_nX_2 & \dots & X_n^2 \end{bmatrix} = \begin{bmatrix} EX_1^2 & E[X_1X_2] & \dots & E[X_1X_n] \\ EX_2X_1 & E[X_2^2] & \dots & E[X_2X_n] \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ E[X_nX_1] & E[X_nX_2] & \dots & E[X_n^2] \end{bmatrix},$$

Variáveis Aleatórias Multidimensionais

Matriz de Covariância

$$Cov(X1,X2) = C_{x1,x2} = C_{x2,x1} = \frac{\sum_{i=1}^{n}[x1(i) - mx1)(x2(i) - mx2]}{n}$$

$$\mathbf{C_X} = \mathbf{E[(X - EX)(X - EX)^T]}$$

$$= E\begin{bmatrix} (X_1 - EX_1)^2 & (X_1 - EX_1)(X_2 - EX_2) & \dots & (X_1 - EX_1)(X_n - EX_n) \\ (X_2 - EX_2)(X_1 - EX_1) & (X_2 - EX_2)^2 & \dots & (X_2 - EX_2)(X_n - EX_n) \\ \vdots & \vdots & \vdots & \vdots \\ (X_n - EX_n)(X_1 - EX_1) & (X_n - EX_n)(X_2 - EX_2) & \dots & (X_n - EX_n)^2 \end{bmatrix}$$

$$= \begin{bmatrix} \mathrm{Var}(X_1) & \mathrm{Cov}(X_1, X_2) & \dots & \mathrm{Cov}(X_1, X_n) \\ \mathrm{Cov}(X_2, X_1) & \mathrm{Var}(X_2) & \dots & \mathrm{Cov}(X_2, X_n) \\ \vdots & \vdots & \vdots & \vdots \\ \mathrm{Cov}(X_n, X_1) & \mathrm{Cov}(X_n X_2) & \dots & \mathrm{Var}(X_n) \end{bmatrix}.$$

Variáveis Aleatórias Multidimensionais

Matriz de Covariância

Correlation matrix of X:

$$\mathbf{R_X} = \mathbf{E}[\mathbf{X}\mathbf{X}^{\mathbf{T}}]$$

Covariance matrix of X:

$$\mathbf{C_X} = \mathbf{E}[(\mathbf{X} - \mathbf{EX})(\mathbf{X} - \mathbf{EX})^{\mathbf{T}}] = \mathbf{R_X} - \mathbf{EXEX}^{\mathbf{T}}$$

$$\begin{aligned}
\mathbf{C_X} &= \mathbf{E}[(\mathbf{X} - \mathbf{EX})(\mathbf{X} - \mathbf{EX})^{\mathbf{T}}] \\
&= \mathbf{E}[(\mathbf{X} - \mathbf{EX})(\mathbf{X}^{\mathbf{T}} - \mathbf{EX}^{\mathbf{T}})] \\
&= \mathbf{E}[\mathbf{X}\mathbf{X}^{\mathbf{T}}] - \mathbf{EXEX}^{\mathbf{T}} - \mathbf{EXEX}^{\mathbf{T}} + \mathbf{EXEX}^{\mathbf{T}} \\
&= \mathbf{R_X} - \mathbf{EXEX}^{\mathbf{T}}.
\end{aligned}$$

Variáveis Aleatórias Multidimensionais

Matriz de Covariância – Exemplo

$$\mathbf{Y} = \mathbf{AX} + \mathbf{b},$$

$$\mathbf{EY} = \mathbf{AEX} + \mathbf{b}.$$

$$\mathbf{C_Y} = \mathbf{AC_X A^T}.$$

$$\begin{aligned}
\mathbf{C_Y} &= \mathbf{E[(Y - EY)(Y - EY)^T]} \\
&= \mathbf{E[(AX + b - AEX - b)(AX + b - AEX - b)^T]} \\
&= E[\mathbf{A(X - EX)(X - EX)^T A^T}] \\
&= \mathbf{AE[(X - EX)(X - EX)^T]A^T} \\
&= \mathbf{AC_X A^T}.
\end{aligned}$$

Variáveis Aleatórias Multidimensionais

- Exemplo:

$$f_{X,Y}(x,y) = \begin{cases} \frac{3}{2}x^2 + y & 0 < x, y < 1 \\ 0 & \text{otherwise} \end{cases}$$

$$\mathbf{U} = \begin{bmatrix} X \\ Y \end{bmatrix}.$$

$$f_X(x) = \int_0^1 \frac{3}{2}x^2 + y \; dy$$
$$= \frac{3}{2}x^2 + \frac{1}{2}, \quad \text{for } 0 < x < 1.$$

$$f_Y(y) = \int_0^1 \frac{3}{2}x^2 + y \; dx$$
$$= y + \frac{1}{2}, \quad \text{for } 0 < y < 1.$$

$EX = \frac{5}{8}$, $EX^2 = \frac{7}{15}$, $EY = \frac{7}{12}$, and $EY^2 = \frac{5}{12}$

$$EXY = \int_0^1 \int_0^1 xy\left(\frac{3}{2}x^2 + y\right) dxdy$$
$$= \int_0^1 \frac{3}{8}y + \frac{1}{2}y^2 dy$$
$$= \frac{17}{48}.$$

Variáveis Aleatórias Multidimensionais

- Exemplo: cont.

$$f_{X,Y}(x,y) = \begin{cases} \frac{3}{2}x^2 + y & 0 < x, y < 1 \\ 0 & \text{otherwise} \end{cases}$$

$$\mathbf{U} = \begin{bmatrix} X \\ Y \end{bmatrix}.$$

$EX = \frac{5}{8}$, $EX^2 = \frac{7}{15}$, $EY = \frac{7}{12}$, and $EY^2 = \frac{5}{12}$

$$\begin{aligned} EXY &= \int_0^1 \int_0^1 xy\left(\frac{3}{2}x^2 + y\right) dxdy \\ &= \int_0^1 \frac{3}{8}y + \frac{1}{2}y^2 dy \\ &= \frac{17}{48}. \end{aligned}$$

$$\begin{aligned} \text{Cov}(X,Y) &= EXY - EXEY \\ &= \frac{17}{48} - \frac{5}{8}.\frac{7}{12} \\ &= -\frac{1}{96}. \end{aligned}$$

$$\mathbf{R_U} = \mathbf{E}[\mathbf{U}\mathbf{U}^\mathbf{T}] = \begin{bmatrix} EX^2 & EXY \\ EYX & EY^2 \end{bmatrix} = \begin{bmatrix} \frac{7}{15} & \frac{17}{48} \\ \frac{17}{48} & \frac{5}{12} \end{bmatrix}.$$

$$\mathbf{C_U} = \begin{bmatrix} \text{Var}(X) & \text{Cov}(X,Y) \\ \text{Cov}(Y,X) & \text{Var}(Y) \end{bmatrix} = \begin{bmatrix} \frac{73}{960} & -\frac{1}{96} \\ -\frac{1}{96} & \frac{11}{144} \end{bmatrix}.$$

Variáveis Aleatórias Multidimensionais

- Exemplo: Aplicação em automação

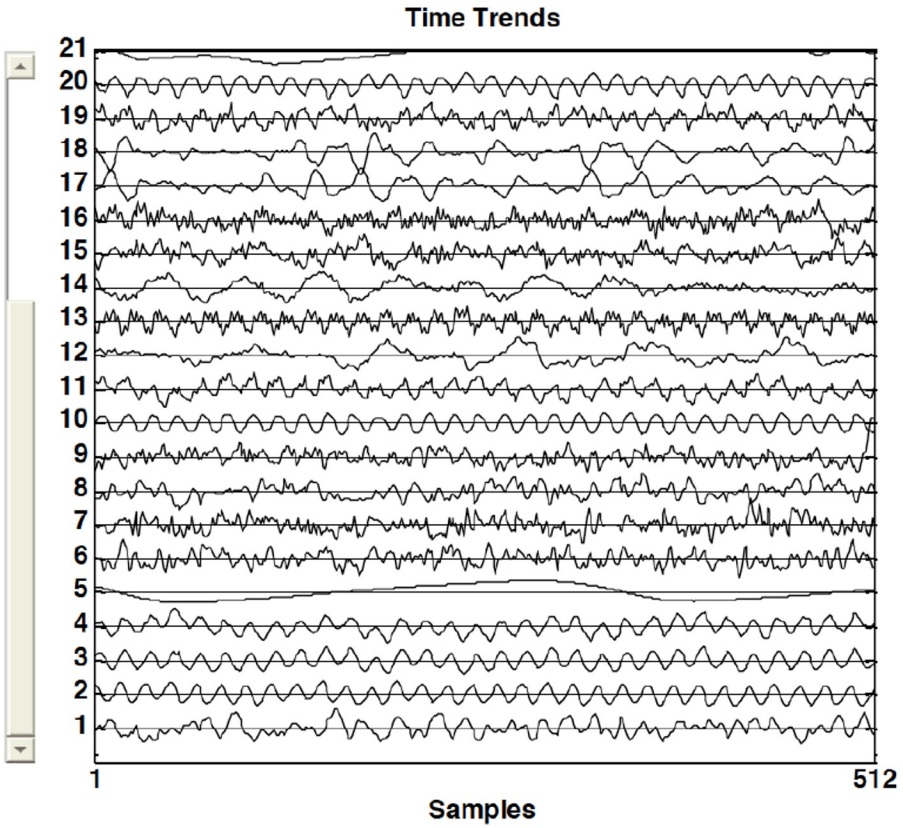

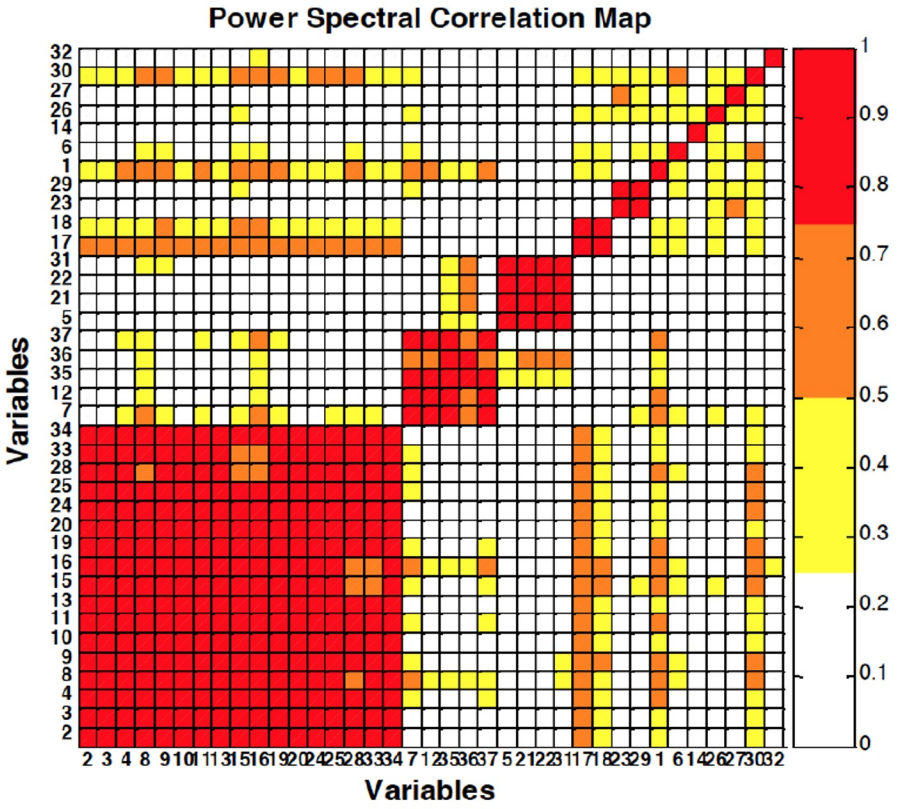

Variáveis Aleatórias Multidimensionais

Matriz de Correlação Cruzada

$$\mathbf{R_{XY}} = \mathbf{E}[\mathbf{X}\mathbf{Y}^{\mathbf{T}}].$$

Matriz de Covariância Cruzada

$$\mathbf{C_{XY}} = \mathbf{E}[(\mathbf{X} - \mathbf{EX})(\mathbf{Y} - \mathbf{EY})^{\mathbf{T}}].$$

Variáveis Aleatórias Multidimensionais

- Distribuição n-dimensional conjuntamente Normal:

For a normal random vector $\mathbf{X}$ with mean $\mathbf{m}$ and covariance matrix $\mathbf{C}$, the PDF is given by

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}}\sqrt{\det \mathbf{C}}} \exp\left\{ -\frac{1}{2}(\mathbf{x}-\mathbf{m})^T \mathbf{C}^{-1}(\mathbf{x}-\mathbf{m}) \right\}$$

- Exemplo para o caso bidimensional.

$$\mathbf{C} = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

$$f_{XY}(x,y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \cdot \exp\left\{ -\frac{1}{2(1-\rho^2)} \left[\left(\frac{x-\mu_X}{\sigma_X}\right)^2 + \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2 - 2\rho\frac{(x-\mu_X)(y-\mu_Y)}{\sigma_X\sigma_Y} \right] \right\}.$$

Variáveis Aleatórias Multidimensionais

- Distribuição Normal Bivariada – com médias nulas

Two random variables X and Y are said to have the **standard bivariate normal distribution with correlation coefficient** ρ if their joint PDF is given by

$$f_{XY}(x,y) = \frac{1}{2\pi\sqrt{1-\rho^2}}\exp\{-\frac{1}{2(1-\rho^2)}\left[x^2 - 2\rho xy + y^2\right]\},$$

where $\rho \in (-1,1)$. If $\rho = 0$, then we just say X and Y have the standard bivariate normal distribution.

Variáveis Aleatórias Multidimensionais

- Distribuição n-dimensional conjuntamente normal:
  - Exemplo para o caso bidimensional.
    - Se x e y forem descorrelacionados (independentes), temos:
      - $\rho = 0$,
      - $f_{xy}(X,Y) = f_x(X).\ f_y(Y)$
      - $f_{x/y}(X/Y) = f_x(X)$
      - $f_y(Y/X) = f_y(Y)$

$$f_{XY}(x,y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \cdot \exp\left\{ -\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_X}{\sigma_X}\right)^2 + \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2 - 2\rho\frac{(x-\mu_X)(y-\mu_Y)}{\sigma_X\sigma_Y}\right]\right\}.$$

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{1}{(2\pi)^{\frac{n}{2}}\sqrt{\det \mathbf{C}}} \exp\left\{ -\frac{1}{2}(\mathbf{x}-\mathbf{m})^T \mathbf{C}^{-1}(\mathbf{x}-\mathbf{m}) \right\}$$

$$\mathbf{C} = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

Distribuição Normal Bivariada

Theorem 5.4
Suppose X and Y are jointly normal random variables with parameters μ_X, σ_X^2, μ_Y, σ_Y^2, and ρ. Then, given $X = x$, Y is normally distributed with

$$E[Y|X = x] = \mu_Y + \rho\sigma_Y \frac{x - \mu_X}{\sigma_X},$$
$$Var(Y|X = x) = (1 - \rho^2)\sigma_Y^2.$$

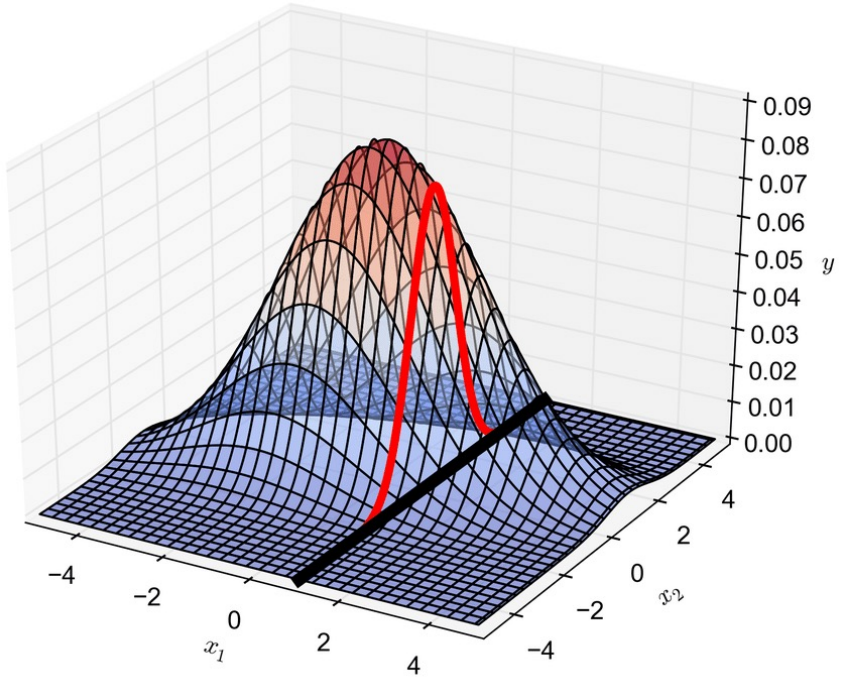

Normal Bidimensional

- ρ = 0, ρ = +/- 1,
- Verificar o formato das curvas de superfície.
- Interpretação.

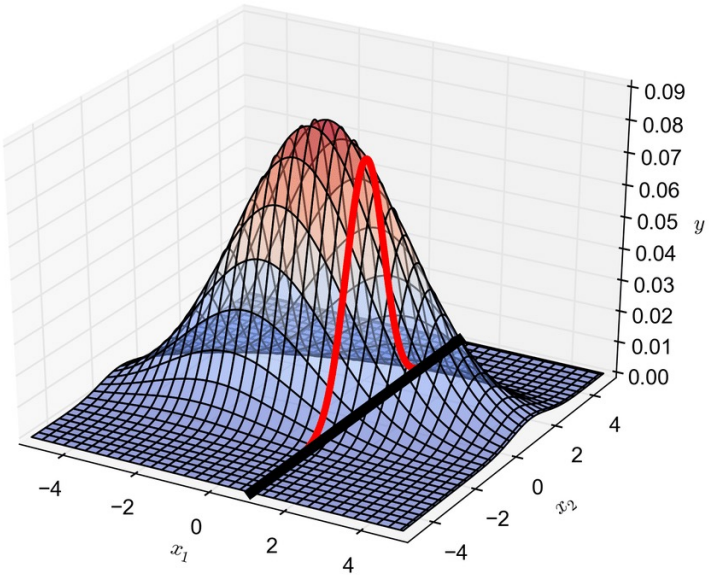

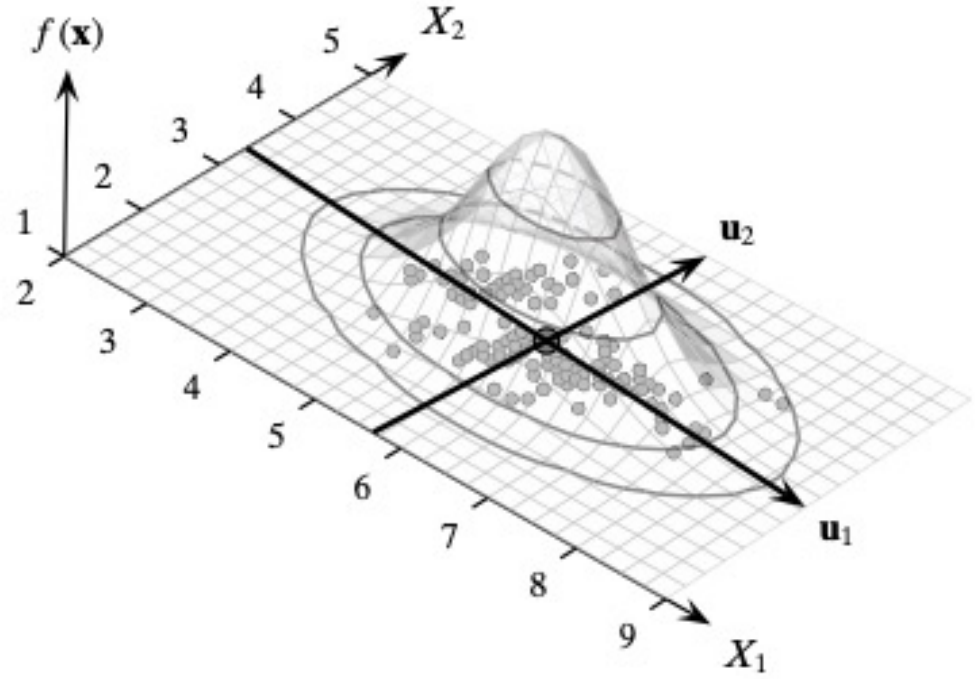

$$f_{XY}(x,y) = \frac{1}{2\pi\sigma_X\sigma_Y\sqrt{1-\rho^2}} \cdot \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_X}{\sigma_X}\right)^2 + \left(\frac{y-\mu_Y}{\sigma_Y}\right)^2 - 2\rho\frac{(x-\mu_X)(y-\mu_Y)}{\sigma_X\sigma_Y}\right]\right\}.$$

$$C = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

Variáveis Aleatórias Multidimensionais

- Distribuição Normal Bivariada

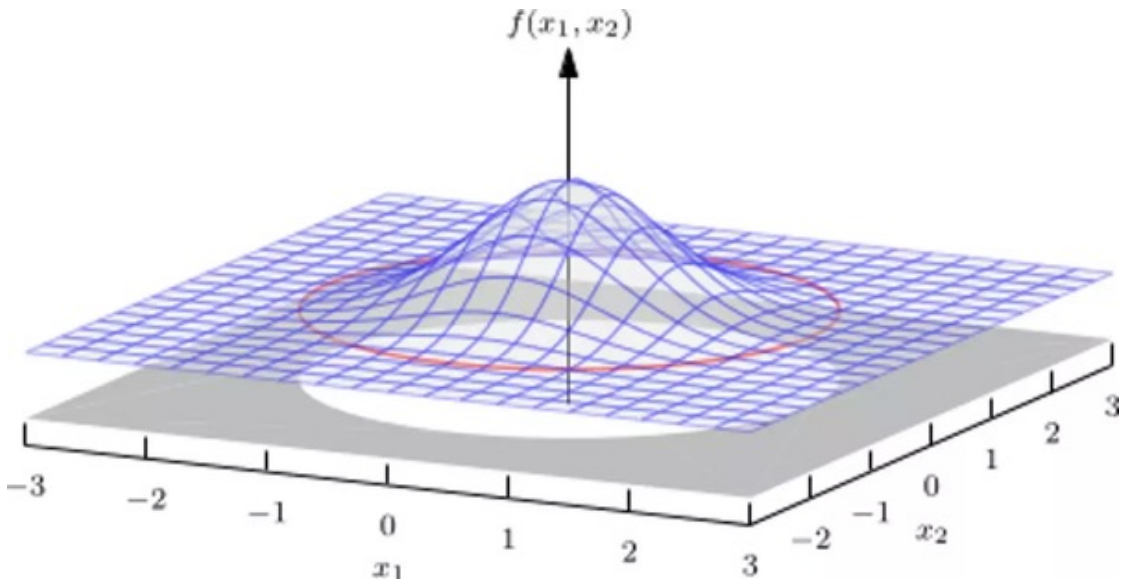

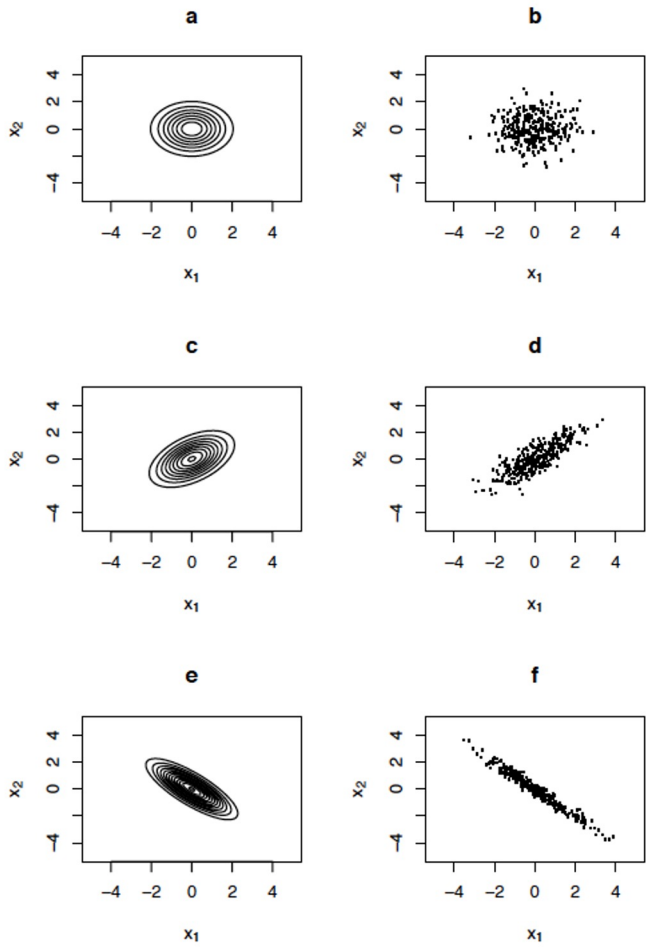

$x_2 = a\, x_1 + b$

Figure 5.12: Bivariate Normal density. $\mathbb{E}[X_1] = \mathbb{E}[X_2] = 0$; $\sigma_1 = \sigma_2 = 1$.
(a), (b): $\sigma_{1,2} = 0$.
(c), (d): $\sigma_{1,2} = .5$.
(e), (f): $\sigma_{1,2} = -.8$.
(a), (c), (e): contours of the joint density.
(b), (d), (f): samples from the joint density.

Normal Bidimensional

- ρ = 0, ρ = +/- 1,
- Verificar o formato das curvas de superfície.
- Interpretação.

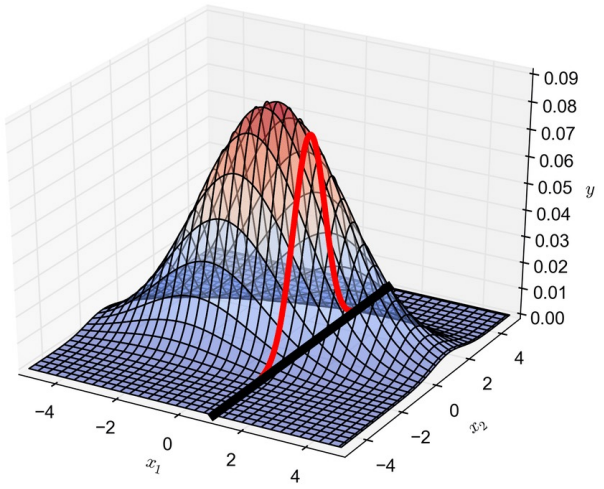

$$C = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

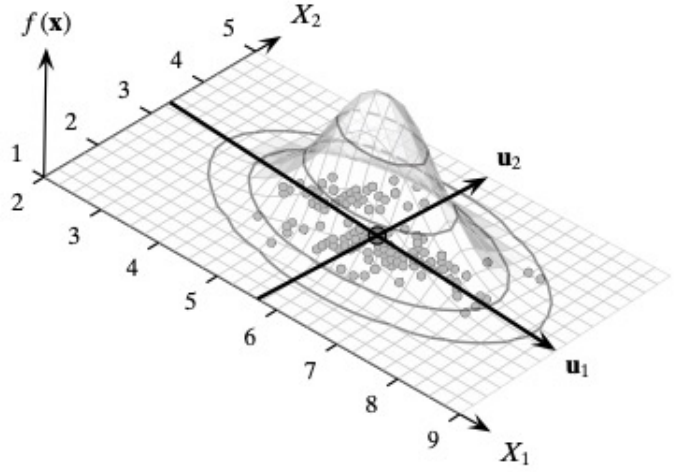

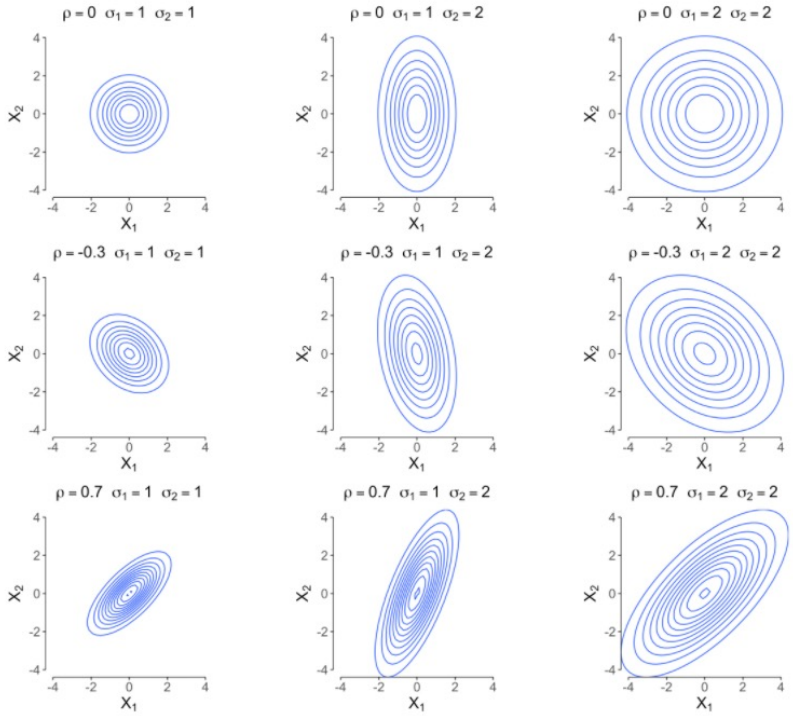

Normal Bidimensional

- ρ = 0, ρ = +/- 1,
- Verificar o formato das curvas de superfície.
- Interpretação.

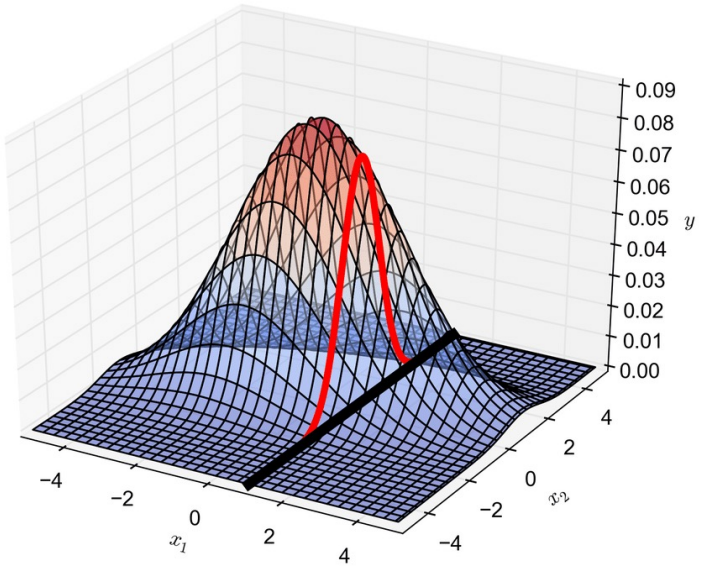

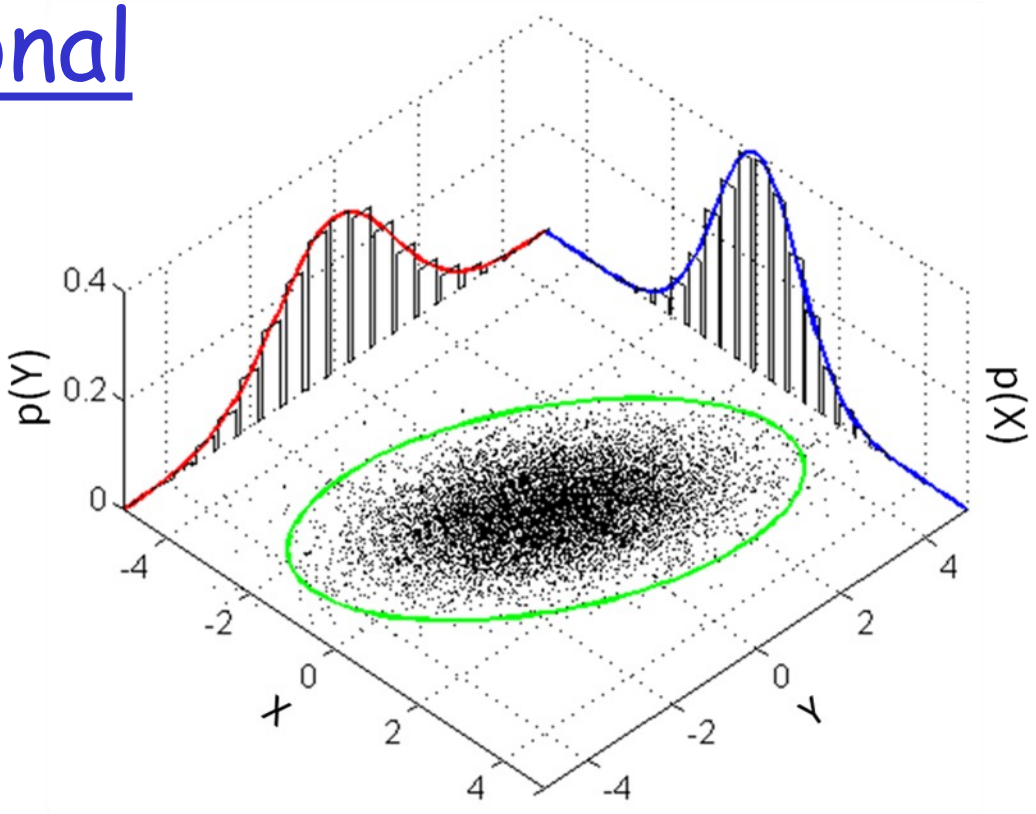

$$C = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

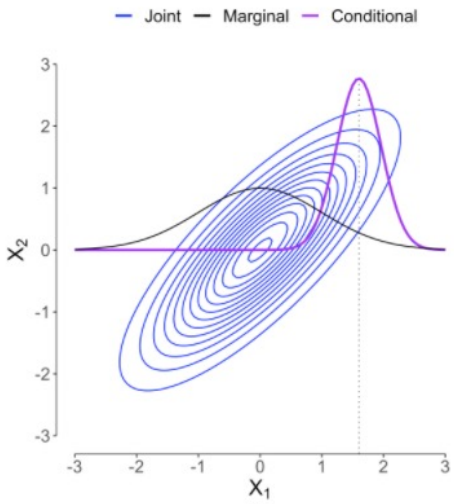

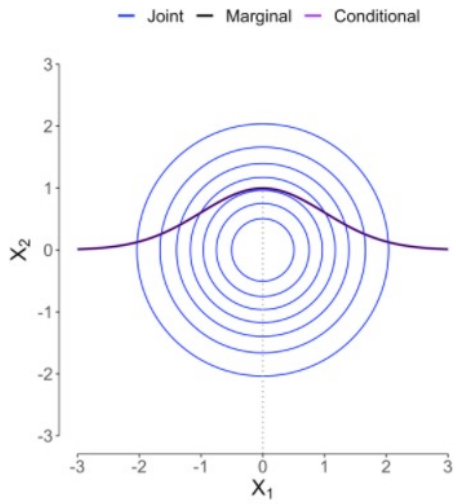

Normal Bidimensional

Uma questão

- Rotação
- Translação
- Escala

$$C = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$$

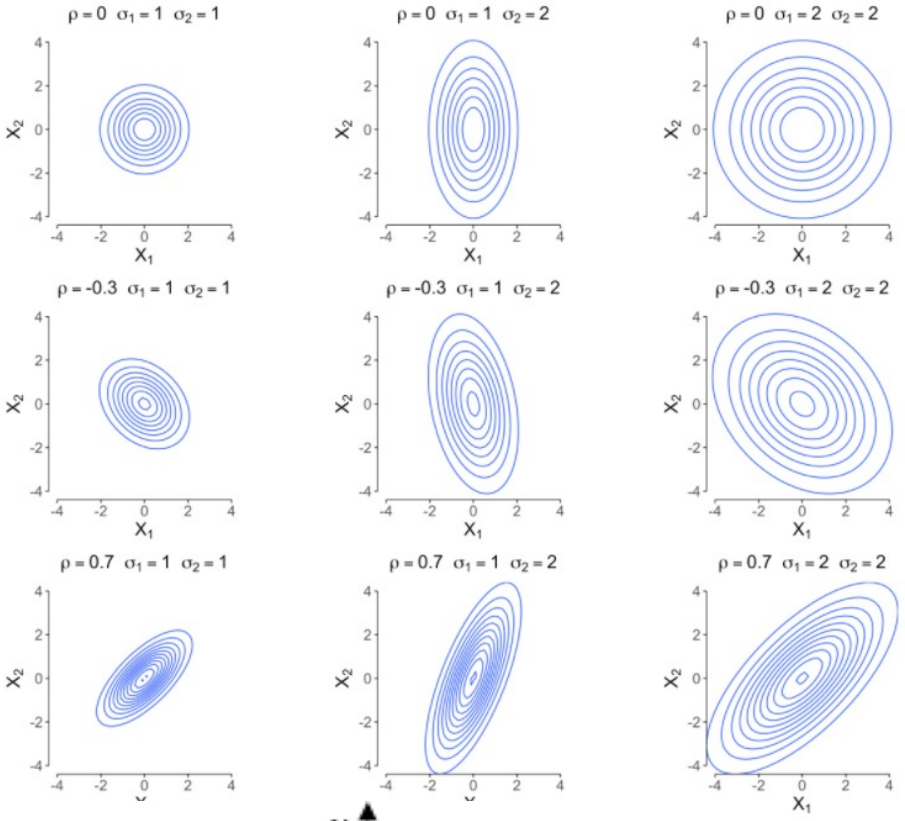

Componente de rotação

Componente de translação

$$\begin{bmatrix} x_1 \\ y_1 \\ 1 \end{bmatrix} = \begin{bmatrix} \cos\theta & -\sin\theta & p_x \\ \sin\theta & \cos\theta & p_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

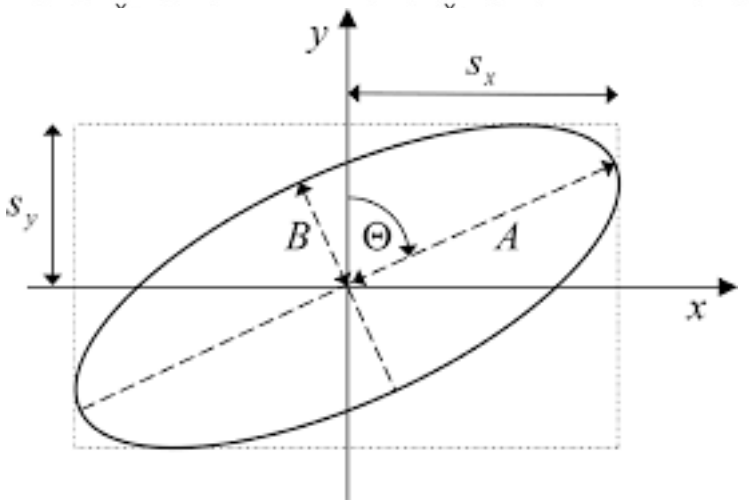

Hora do Mister M

Medidas Estatística

- Similaridade
- Divergência
- Distância

Medidas de Distância

- Características de medidas de distâncias

1. $d(\mathbf{x}_i, \mathbf{x}_i) = 0$ para todo $\mathbf{x}_i$ (Os objetos não são diferentes de si próprios)
2. $d(\mathbf{x}_i, \mathbf{x}_j) = d(\mathbf{x}_j, \mathbf{x}_i)$ (Simetria)
3. $d(\mathbf{x}_i, \mathbf{x}_j) \geq 0$ para todo $\mathbf{x}_i$ e $\mathbf{x}_j$ (Positividade)
4. $d(\mathbf{x}_i, \mathbf{x}_j) = 0$ somente se $\mathbf{x}_i = \mathbf{x}_j$
5. $d(\mathbf{x}_i, \mathbf{x}_l) \leq d(\mathbf{x}_i, \mathbf{x}_j) + d(\mathbf{x}_j, \mathbf{x}_l)$ para todo $\mathbf{x}_i$, $\mathbf{x}_j$ e $\mathbf{x}_l$ (Desigualdade triangular)

Medidas de Similaridade

- É uma função de valor real que quantifica a similaridade entre duas amostras de dados.
  - Valores alto → amostras muito similares
  - Valores pequenos → amostras dissimilares
  - A medida de similaridade deve manter a propriedade de simetria

Medidas de Divergência

- Divergência é uma função em estatística que mede a diferença direcionada (assimetria) de duas distribuições de probabilidades.
  - Propriedades da medida de divergência

(1) Non-negativity:

$$\mathrm{div}(P_1(x)\|P_2(x)) \geq 0$$

(2) Identity of indiscernible:

$$\mathrm{div}(P_1(x)\|P_2(x)) = 0 \, iff \, P_1(x) = P_2(x)$$

  - Não precisa satisfazer as propriedades de simetria e desigualdade triangular

Medidas de Divergência

- Divergência de Kullback-Leibler (KL)
  - Para VA discretas

$$\mathrm{div}_{KL}(P_1(x)\|P_2(x)) = \sum_x P_1(x)\log\left(\frac{P_1(x)}{P_2(x)}\right)$$

  - Para VA contínuas

$$\mathrm{div}_{KL}(P_1(x)\|P_2(x)) = \int P_1(x)\log\left(\frac{P_1(x)}{P_2(x)}\right)dx$$

Métricas de Distância

- Métricas de distância para atributos quantitativos
  - Distância de Mahattan

$$d(\boldsymbol{x}_i, \boldsymbol{x}_j) = \sum_{l=1}^{N} |x_{i,l} - x_{j,l}|$$

  - Distância de Minkowski:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt[p]{\sum_{l=1}^{d} |x_i^l - x_j^l|^p}$$

  - Distância Euclidiana:

$$d(\mathbf{x}_i, \mathbf{x}_j) = \sqrt{(\sum_{l=1}^{d} (x_i^l - x_j^l)^2}$$

  - Distância de Mahalanobis:

$$D_M(x) = \sqrt{(x-\mu)^\intercal S^{-1} (x-\mu)}.$$

$$d(\vec{x}, \vec{y}) = \sqrt{\sum_{i=1}^{p} \frac{(x_i - y_i)^2}{\sigma_i^2}},$$

Métricas de Distância

- Comparação entre as distância de Mahattan e Euclidiana

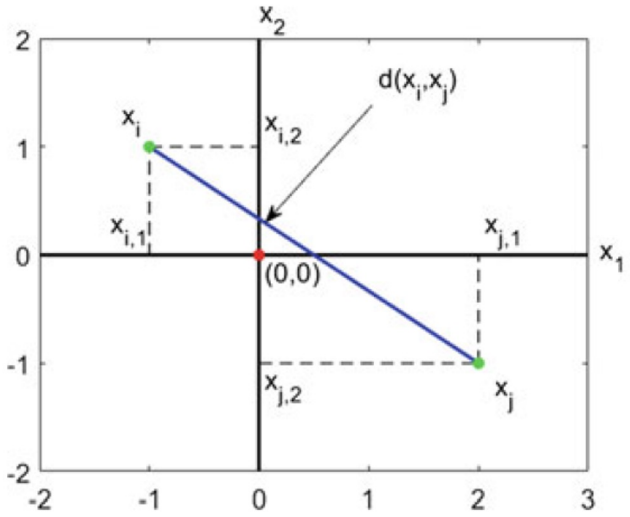

(a) Euclidean distance

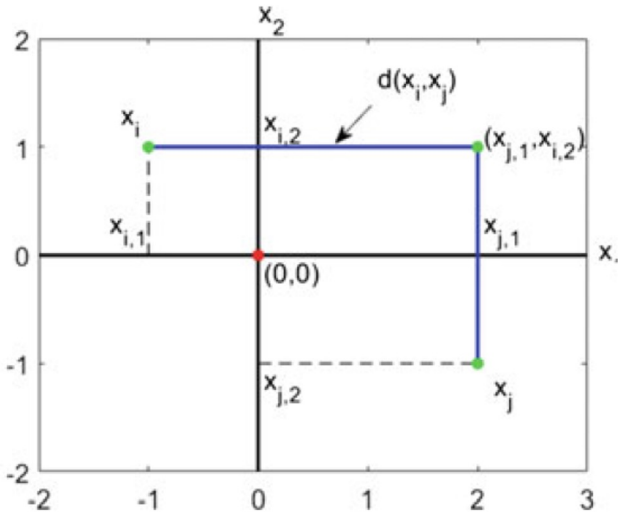

(b) City block distance

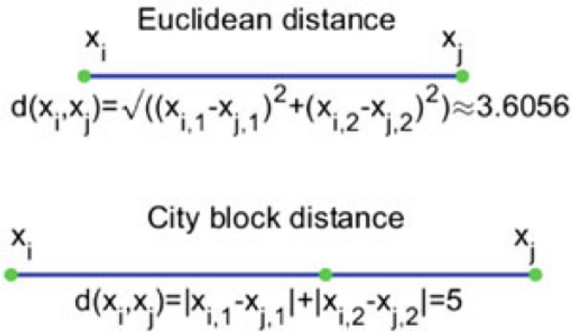

(c) Comparison between the Euclidean and city block distances in *1D*

Métricas de Distância

- Distância de Mahalanobis: medida de sin

$$d(\boldsymbol{x}_i, \boldsymbol{x}_j) = \sqrt{(\boldsymbol{x}_i - \boldsymbol{x}_j)^T \boldsymbol{\Sigma}_K^{-1} (\boldsymbol{x}_i - \boldsymbol{x}_j)}$$

$$\boldsymbol{\mu}_K = \frac{1}{K} \sum_{i=1}^{K} \boldsymbol{x}_i;$$

- Onde, temos a média dada por:

- A matriz de covariância é dada por:

$$\boldsymbol{\Sigma}_K = \frac{1}{K} \sum_{i=1}^{K} (\boldsymbol{x}_i - \boldsymbol{\mu}_K)(\boldsymbol{x}_i - \boldsymbol{\mu}_K)^T$$

Métricas de Distância

- Distância de Mahalanobis:
  - A distância euclidiana é um caso particular.

$$\Sigma_K = \mathbf{I} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{bmatrix}$$

  - Quando a matriz de covariância for diagonal, variáveis descorrelacionadas, temos um processo de normalização:

$$d(\vec{x}, \vec{y}) = \sqrt{\sum_{i=1}^{p} \frac{(x_i - y_i)^2}{\sigma_i^2}}, \qquad d(\boldsymbol{x}_i, \boldsymbol{x}_j) = \sqrt{(\boldsymbol{x}_i - \boldsymbol{x}_j)^T \boldsymbol{\Sigma}_K^{-1} (\boldsymbol{x}_i - \boldsymbol{x}_j)}$$

Dissimilaridade Cosseno

- Mede a similaridade entre o cosseno de dois ângulo entre dois vetores não nulos do espaço do produto interno.
- Formalmente, temos:

$$d(\boldsymbol{x}_i, \boldsymbol{x}_j) = \cos\left(\theta_{\boldsymbol{x}}^{i,j}\right)$$

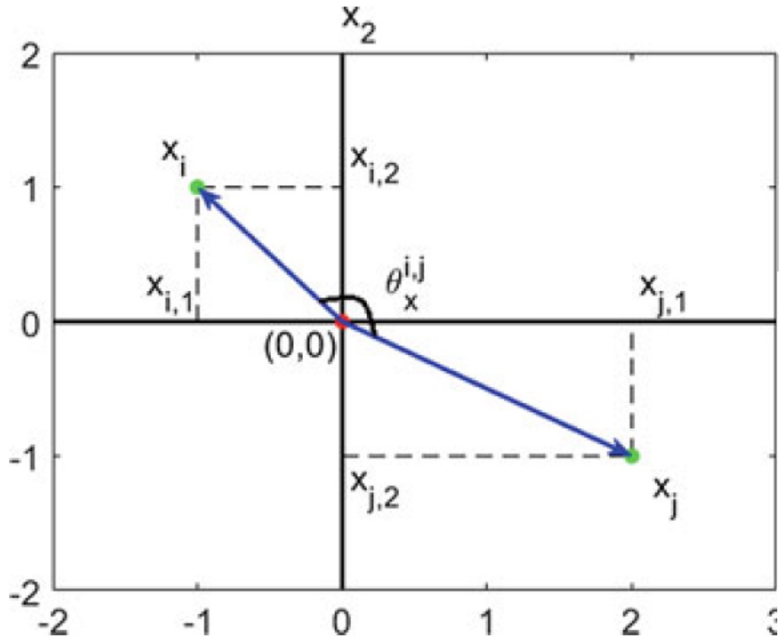

$$d(\boldsymbol{x}_i, \boldsymbol{x}_j) = \frac{\langle \boldsymbol{x}_i, \boldsymbol{x}_j \rangle}{\|\boldsymbol{x}_i\| \|\boldsymbol{x}_j\|}$$

$$\langle \boldsymbol{x}_i, \boldsymbol{x}_j \rangle = \sum_{l=1}^{N} x_{i,l} x_{j,l} \qquad \|\boldsymbol{x}_i\| = \sqrt{\langle \boldsymbol{x}_i, \boldsymbol{x}_i \rangle}.$$

$$\frac{\sum_{l=1}^{N} x_{i,l} x_{j,l}}{\|\boldsymbol{x}_i\| \|\boldsymbol{x}_j\|} = \frac{\sum_{l=1}^{N} x_{i,l} x_{j,l}}{\|\boldsymbol{x}_i\| \|\boldsymbol{x}_j\|} - \frac{\sum_{l=1}^{N} x_{j,l}^2}{2\|\boldsymbol{x}_j\|^2} - \frac{\sum_{l=1}^{N} x_{i,l}^2}{2\|\boldsymbol{x}_i\|^2} + 1$$

$$= 1 - \frac{1}{2} \sum_{l=1}^{N} \left(\frac{x_{i,l}}{\|\boldsymbol{x}_i\|} - \frac{x_{j,l}}{\|\boldsymbol{x}_j\|} \right)^2$$

Dissimilaridade Cosseno

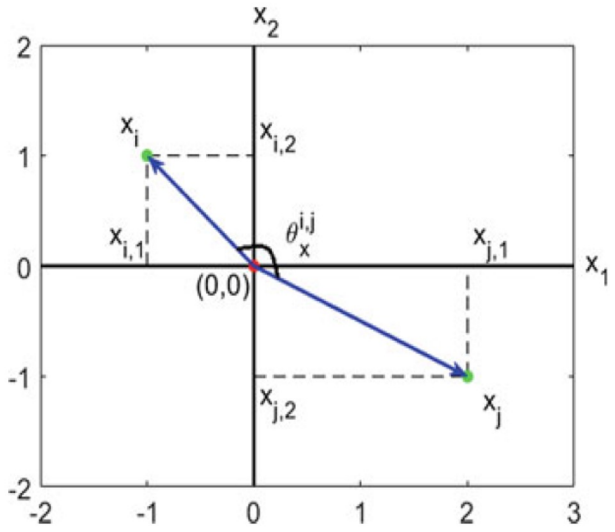

$$d(\boldsymbol{x}_i, \boldsymbol{x}_j) = \cos(\theta_{\boldsymbol{x}}^{i,j})$$

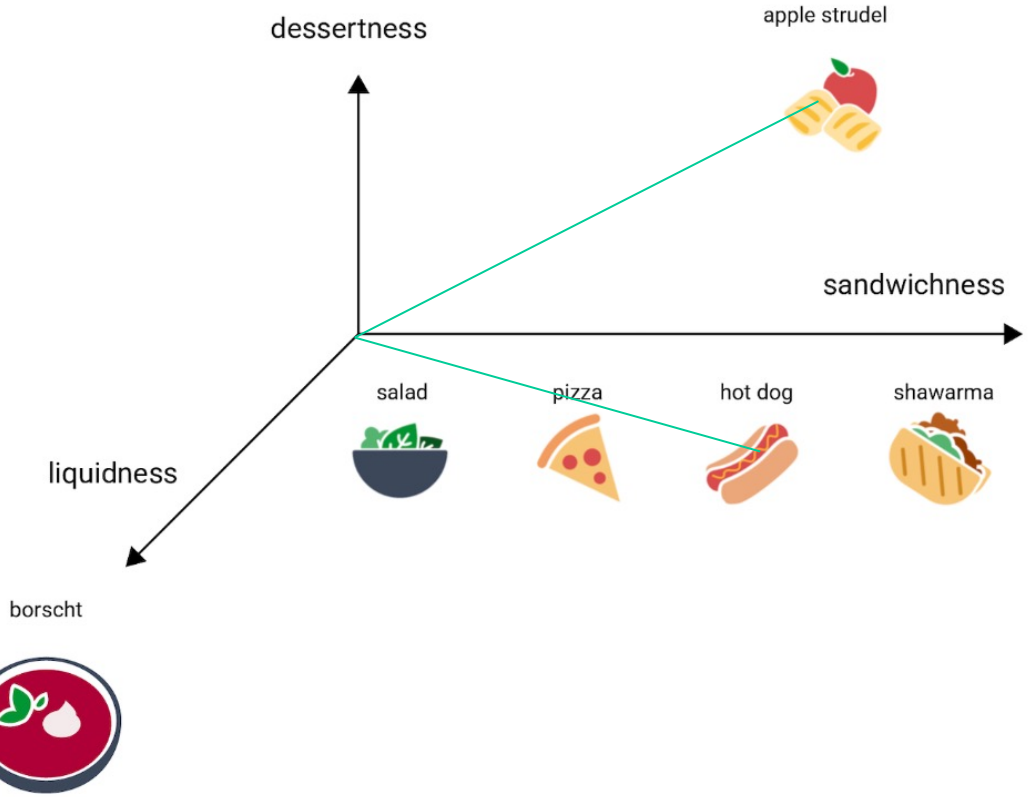

Exemplo – Distribuição Normal Multivariada

- Dado um vetor randômico d-dimensional:

$$\mathbf{X} = (X_1, X_2, \ldots, X_d)^T$$

  - Com distribuição Normal:

$$f(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(\sqrt{2\pi})^d \sqrt{|\boldsymbol{\Sigma}|}} \exp\left\{-\frac{(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})}{2}\right\}$$

  - Distância de Mahalanobis

$$(\mathbf{x}_i - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu})$$

  - Distância euclidiana

$$(\mathbf{x}_i - \boldsymbol{\mu})^T \mathbf{I}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}) = \|\mathbf{x}_i - \boldsymbol{\mu}\|^2$$

Exemplo – Distribuição Normal Multivariada

- Distribuição Normal bivariada padrão:

$$f(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(\sqrt{2\pi})^d \sqrt{|\boldsymbol{\Sigma}|}} \exp\left\{-\frac{(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})}{2}\right\}$$

$$\boldsymbol{\mu} = \mathbf{0} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

$$\boldsymbol{\Sigma} = \mathbf{I} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

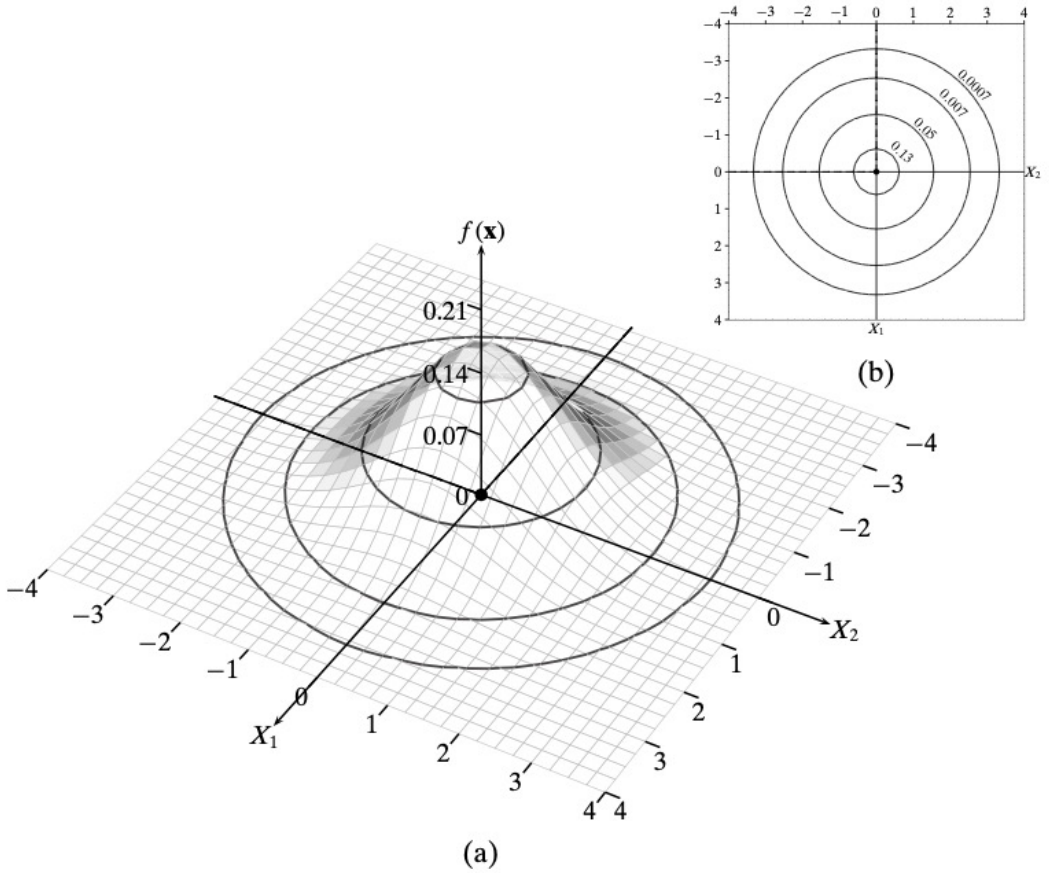

Figure 2.6. (a) Standard bivariate normal density and (b) its contour plot. Parameters: $\boldsymbol{\mu} = (0, 0)^T$, $\boldsymbol{\Sigma} = \mathbf{I}$.

Distribuição Normal Multivariada

- Interpretação Geométrica
  - A equação dos autovalores e autovetores da matriz de covariância é dado por:

$$\boldsymbol{\Sigma}\mathbf{u}_i = \lambda_i \mathbf{u}_i$$

  - Como a matriz de covariância é simétrica positiva semidefinida, temos que:

$$\lambda_1 \geq \lambda_2 \geq \ldots \lambda_d \geq 0$$

$$\mathbf{u}_i^T \mathbf{u}_i = 1 \quad \text{for all } i$$

$$\mathbf{u}_i^T \mathbf{u}_j = 0 \quad \text{for all } i \neq j$$

$$\boldsymbol{\Lambda} = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_d \end{pmatrix}$$

$$\boldsymbol{\Sigma} = \mathbf{U}\boldsymbol{\Lambda}\mathbf{U}^T$$

$$\mathbf{U} = \begin{pmatrix} | & | & & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_d \\ | & | & & | \end{pmatrix}$$

$$\det(\boldsymbol{\Sigma}) = \prod_{i=1}^{d} \lambda_i$$

$$f(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(\sqrt{2\pi})^d \sqrt{|\boldsymbol{\Sigma}|}} \exp\left\{ -\frac{(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x}-\boldsymbol{\mu})}{2} \right\}$$

Distribuição Normal Multivariada

Example 2.8 (Bivariate Normal Density). Treating attributes `sepal length` (X_1) and `sepal width` (X_2) in the Iris dataset (see Table 1.1) as continuous random variables, we can define a continuous bivariate random variable $\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \end{pmatrix}$. Assuming that $\mathbf{X}$ follows a bivariate normal distribution, we can estimate its parameters from the sample. The sample mean is given as

$$\hat{\boldsymbol{\mu}} = (5.843, 3.054)^T$$

and the sample covariance matrix is given as

$$\hat{\boldsymbol{\Sigma}} = \begin{pmatrix} 0.681 & -0.039 \\ -0.039 & 0.187 \end{pmatrix}$$

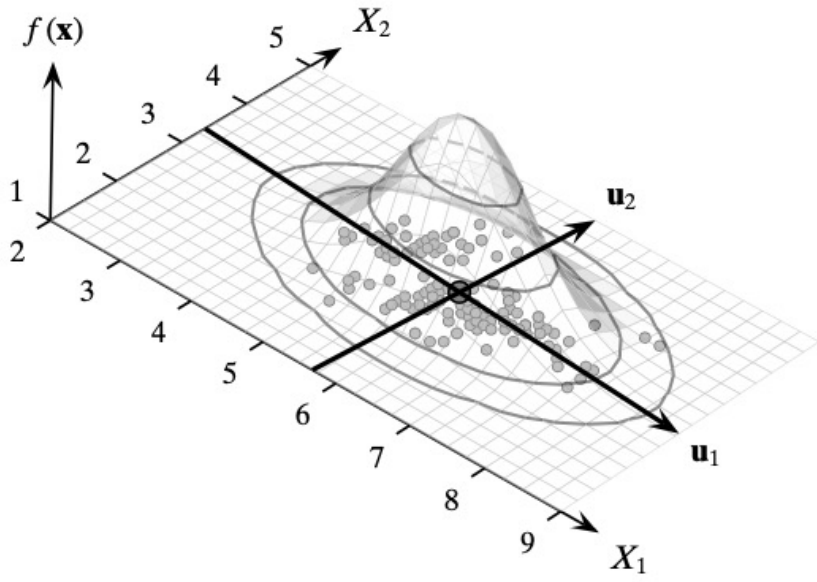

Distribuição Normal Multivariada

Consider the point $\mathbf{x}_2 = (6.9, 3.1)^T$. We have

$$\mathbf{x}_2 - \hat{\boldsymbol{\mu}} = \begin{pmatrix} 6.9 \\ 3.1 \end{pmatrix} - \begin{pmatrix} 5.843 \\ 3.054 \end{pmatrix} = \begin{pmatrix} 1.057 \\ 0.046 \end{pmatrix}$$

$$\hat{\boldsymbol{\mu}} = (5.843, 3.054)^T \qquad \hat{\boldsymbol{\Sigma}} = \begin{pmatrix} 0.681 & -0.039 \\ -0.039 & 0.187 \end{pmatrix}$$

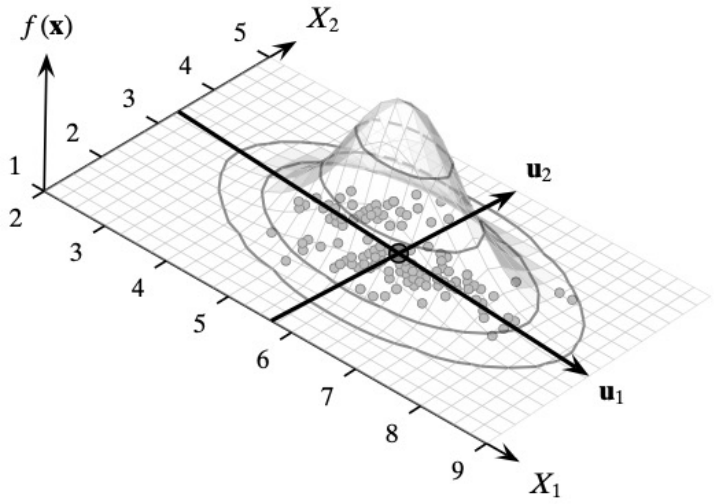

The Mahalanobis distance between $\mathbf{x}_2$ and $\hat{\boldsymbol{\mu}}$ is

$$(\mathbf{x}_i - \hat{\boldsymbol{\mu}})^T \hat{\boldsymbol{\Sigma}}^{-1} (\mathbf{x}_i - \hat{\boldsymbol{\mu}}) = \begin{pmatrix} 1.057 & 0.046 \end{pmatrix} \begin{pmatrix} 0.681 & -0.039 \\ -0.039 & 0.187 \end{pmatrix}^{-1} \begin{pmatrix} 1.057 \\ 0.046 \end{pmatrix}$$

$$= \begin{pmatrix} 1.057 & 0.046 \end{pmatrix} \begin{pmatrix} 1.486 & 0.31 \\ 0.31 & 5.42 \end{pmatrix} \begin{pmatrix} 1.057 \\ 0.046 \end{pmatrix}$$

$$= 1.701$$

whereas the squared Euclidean distance between them is

$$\|(\mathbf{x}_2 - \hat{\boldsymbol{\mu}})\|^2 = \begin{pmatrix} 1.057 & 0.046 \end{pmatrix} \begin{pmatrix} 1.057 \\ 0.046 \end{pmatrix} = 1.119$$

Distribuição Normal Multivariada

Consider the point $\mathbf{x}_2 = (6.9, 3.1)^T$. We have

$$\mathbf{x}_2 - \hat{\boldsymbol{\mu}} = \begin{pmatrix} 6.9 \\ 3.1 \end{pmatrix} - \begin{pmatrix} 5.843 \\ 3.054 \end{pmatrix} = \begin{pmatrix} 1.057 \\ 0.046 \end{pmatrix}$$

$$\hat{\boldsymbol{\mu}} = (5.843, 3.054)^T \qquad \hat{\boldsymbol{\Sigma}} = \begin{pmatrix} 0.681 & -0.039 \\ -0.039 & 0.187 \end{pmatrix}$$

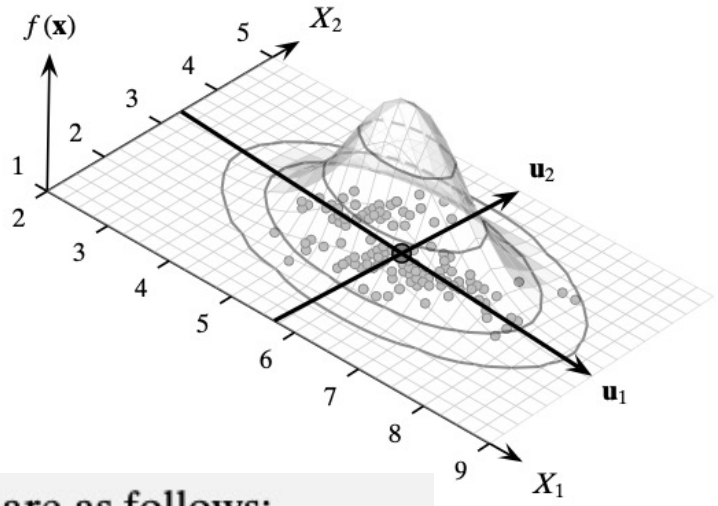

The eigenvalues and the corresponding eigenvectors of $\hat{\boldsymbol{\Sigma}}$ are as follows:

$$\lambda_1 = 0.684 \qquad \mathbf{u}_1 = (-0.997, 0.078)^T$$

$$\lambda_2 = 0.184 \qquad \mathbf{u}_2 = (-0.078, -0.997)^T$$

These two eigenvectors define the new axes in which the covariance matrix is given as

$$\boldsymbol{\Lambda} = \begin{pmatrix} 0.684 & 0 \\ 0 & 0.184 \end{pmatrix}$$

The angle between the original axes $\mathbf{e}_1 = (1, 0)^T$ and $\mathbf{u}_1$ specifies the rotation angle for the multivariate normal:

$$\cos\theta = \mathbf{e}_1^T \mathbf{u}_1 = -0.997$$

$$\theta = \cos^{-1}(-0.997) = 175.5^\circ$$

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation)
  - É basicamente um problema de suavização de histograma de um conjunto de dados finitos de uma determinada VA.
  - São técnicas não-paramétricas para se estimar a PDF de uma VA.
    - Estima a forma da FDP.
    - Utiliza-se a composição de n instâncias de uma função base (kernel)

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation)
  - Seja (x1, x2, ..., xn) uma amostra iid obtida de uma fdp f(x) desconhecida.
    - O estimador de densidade de kernel é dado por:

$$\hat{f}_h(x) = \frac{1}{n}\sum_{i=1}^{n} K_h(x - x_i) \quad = \frac{1}{nh}\sum_{i=1}^{n} K\Big(\frac{x - x_i}{h}\Big),$$

    - Onde, K(.) é o kernel e é uma função simétrica.
    - h>0 é a largura de banda.
    - Kernel de índice h é definido como: $K_h(x) = 1/h\, K(x/h)$

Métodos de Estimação de Densidades

- **KDE (Kernel Density Estimation)**
  - O estimador de densidade de kernel é dado por:

$$\hat{f}_h(x) = \frac{1}{n}\sum_{i=1}^{n} K_h(x - x_i) \quad = \frac{1}{nh}\sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right),$$

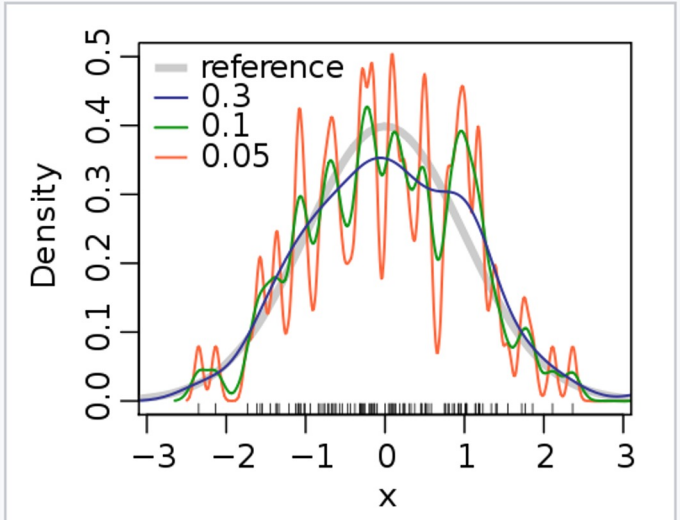

Kernel density estimation of 100 normally distributed random numbers using different smoothing bandwidths.

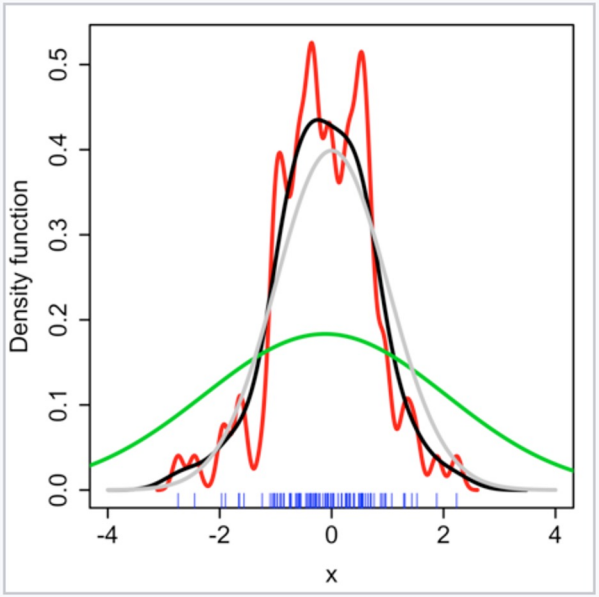

Kernel density estimate (KDE) with different bandwidths of a random sample of 100 points from a standard normal distribution. Grey: true density (standard normal). Red: KDE with h=0.05. Black: KDE with h=0.337. Green: KDE with h=2.

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation)
  - Exemplo: Histograma e KDE
    - Histograma com 6 bins de largura 2
    - KDE com kernel Normal com variância de 2.25.
      - São geradas 6 Gaussianas centralizadas nos respectivos 6 valores dados. O resultado é a soma das gaussianas (kernels)

Sample	1	2	3	4	5	6
Value	-2.1	-1.3	-0.4	1.9	5.1	6.2

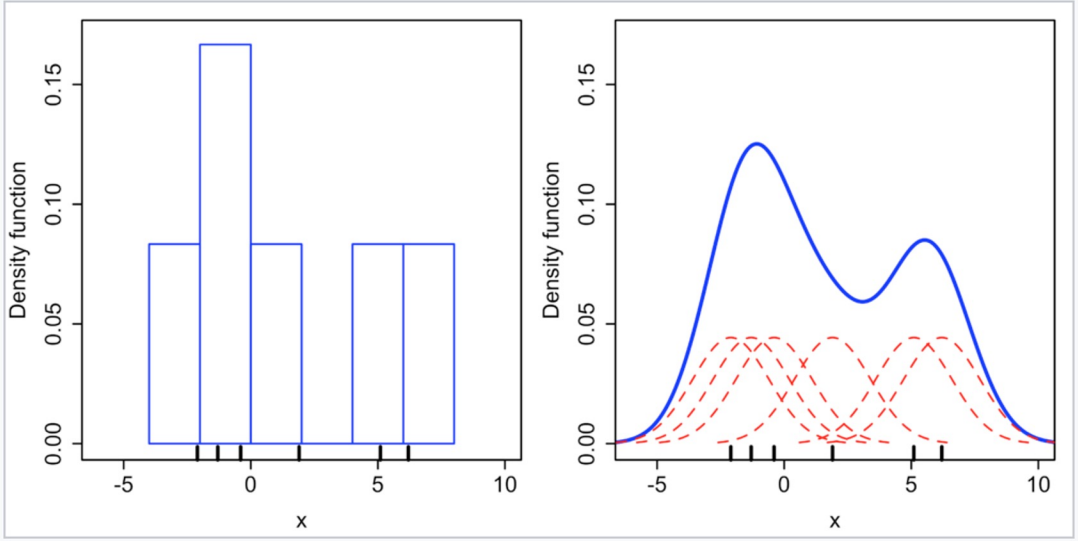

Comparison of the histogram (left) and kernel density estimate (right) constructed using the same data. The 6 individual kernels are the red dashed curves, the kernel density estimate the blue curves. The data points are the rug plot on the horizontal axis.

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation)
  - O parâmetro h tem impacto direto na qualidade da solução obtida.
  - Se o Kernel for Normal, pela regra de Silverman, temos que:

$$h = \left(\frac{4\hat{\sigma}^5}{3n}\right)^{\frac{1}{5}} \approx 1.06\hat{\sigma}n^{-1/5},$$

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation)
  - Característica de Kernel unidimensional

$$\int \kappa(x,h)dx = 1$$

$$\int x\kappa(x,h)dx = 0$$

$$\int x^2\kappa(x,h)dx > 0$$

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation) – Kernels Típicos

(1) Gaussian kernel

$$\kappa(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

(2) Tophat kernel

$$\kappa(x) = \begin{cases} \frac{1}{2} & -1 \le x \le 1 \\ 0 & else \end{cases}$$

(3) Epanechnikov kernel

$$\kappa(x) = \begin{cases} \frac{3}{4}(1 - x^2) & -1 \le x \le 1 \\ 0 & else \end{cases}$$

(4) Exponential kernel

$$\kappa(x) = \frac{1}{2} \exp(-|x|)$$

where $|x|$ denotes the absolute value of x.

(5) Linear kernel

$$\kappa(x) = \begin{cases} 1 - |x| & -1 \le x \le 1 \\ 0 & else \end{cases}$$

(6) Cauchy kernel

$$\kappa(x) = \frac{1}{\pi(1 + x^2)}$$

- Site didático sobre KDE:
  - https://mathisonian.github.io/kde/

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation) – Kernels Típicos

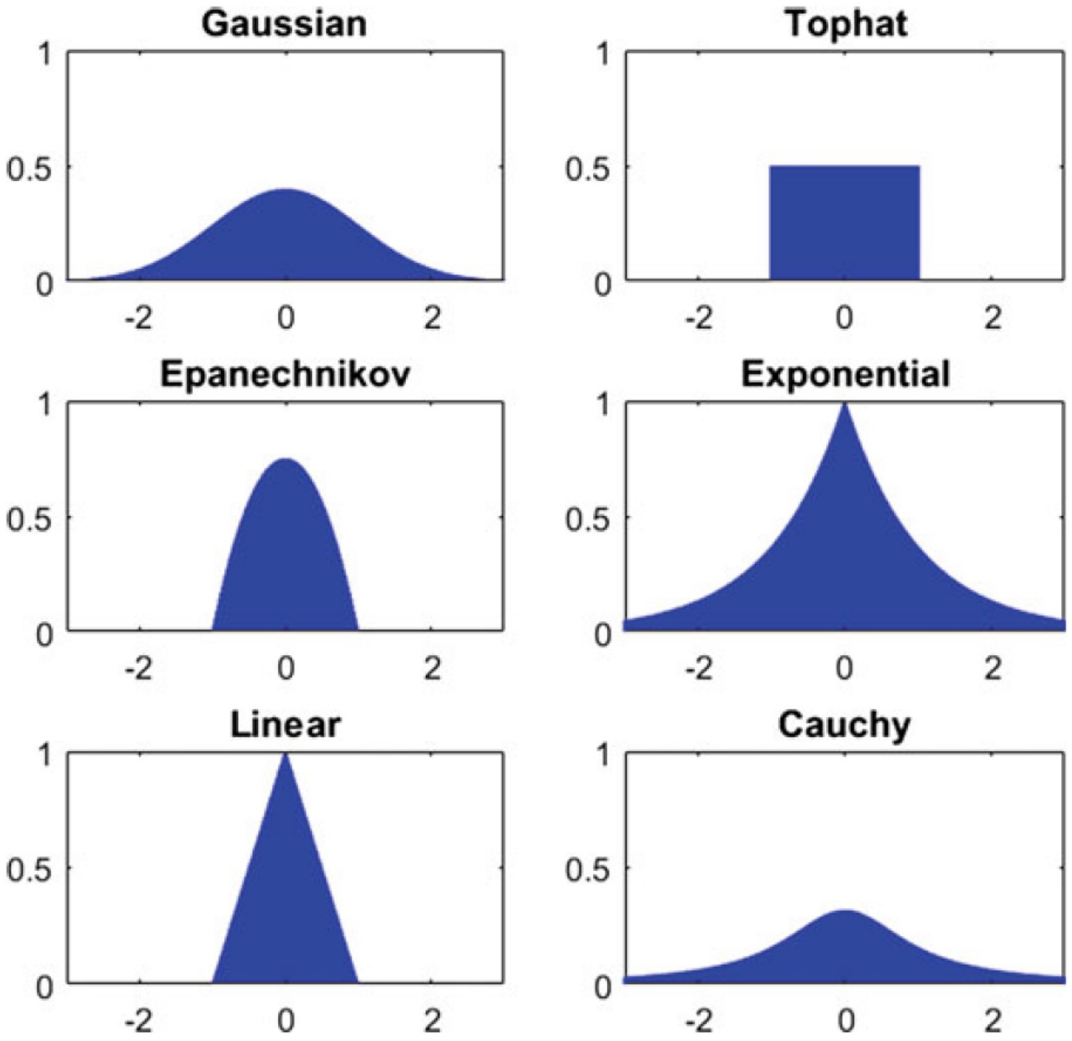

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation) -
  - Exemplo de programa com Python - Scikitlearn

```
>>> from sklearn.neighbors.kde import KernelDensity
>>> import numpy as np
>>> X = np.array([[-1, -1], [-2, -1], [-3, -2], [1, 1], [2, 1], [3, 2]])
>>> kde = KernelDensity(kernel='gaussian', bandwidth=0.2).fit(X)
>>> kde.score_samples(X)
array([-0.41075698, -0.41075698, -0.41076071, -0.41075698, -0.41075698,
       -0.41076071])
```

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation)
  - Caso multivariável: utilizando o mesmo h para todas as dimensões

$$p_{KDE}(x) = \frac{1}{Nh^D}\sum_{n=1}^{N} K\left(\frac{x - x^{(n}}{h}\right)$$

  - Aproximação para o caso multivariável – aproximação produto

$$p_{PKDE}(x) = \frac{1}{N}\sum_{i=1}^{N} K\left(x, x^{(n}, h_1, \ldots h_D\right)$$

$$where\ \ K\left(x, x^{(n}, h_1, \ldots h_D\right) = \frac{1}{h_1 \ldots h_D}\prod_{d=1}^{D} K_d\left(\frac{x_d - x_d^{(n}}{h_d}\right)$$

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation)
  - Exemplo de uma distribuição Normal bivariada unimodal, com 100 amostras.

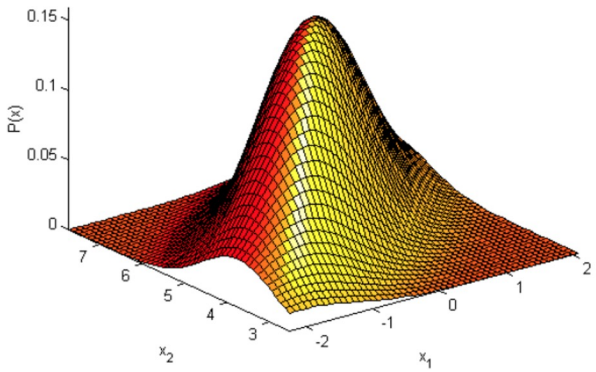

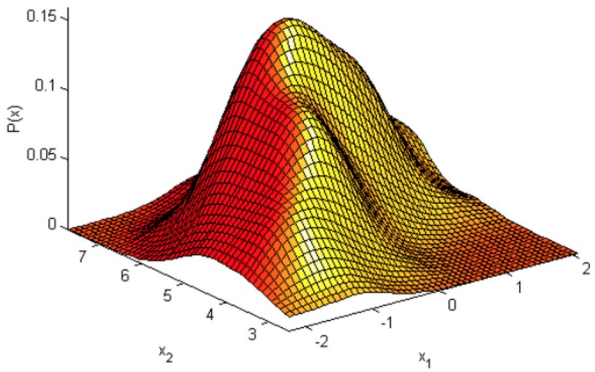

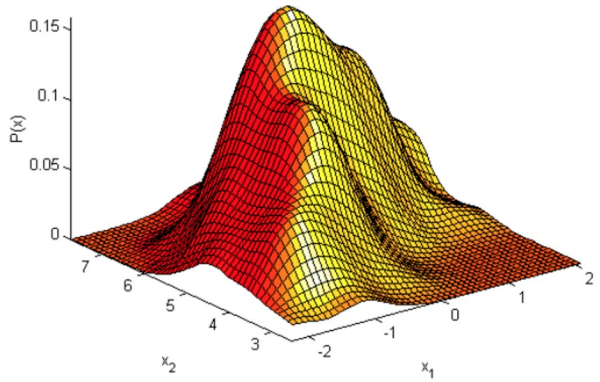

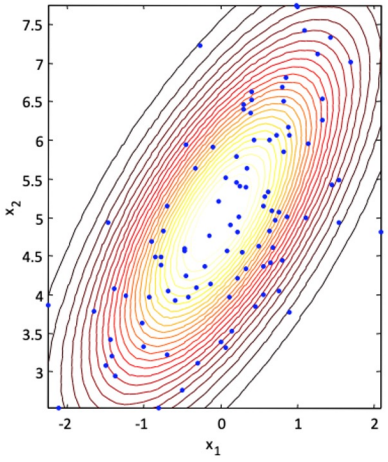

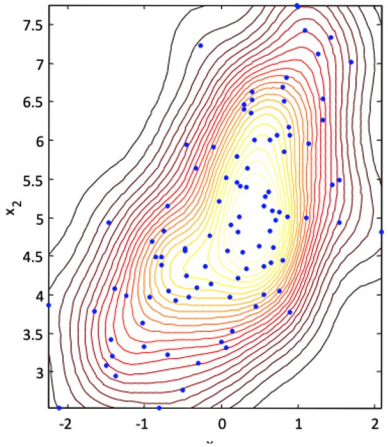

$h = 1.06\sigma N^{-1/5}$

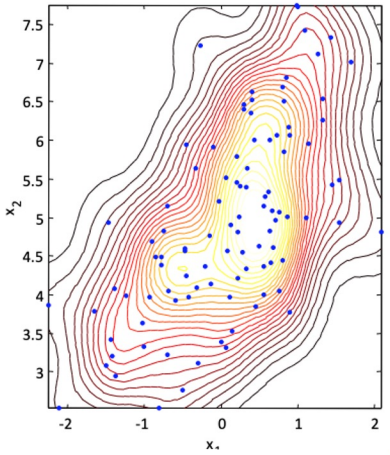

$h = 0.9AN^{-1/5}$

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation)
  - Exemplo de uma distribuição Normal bivariada bimodal, com 100 amostras.

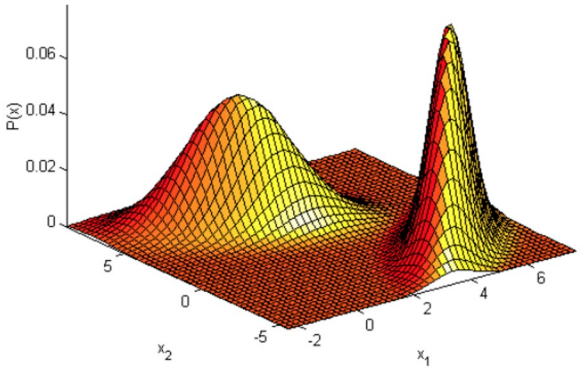

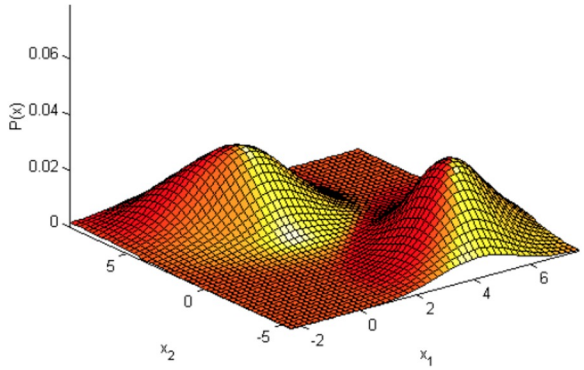

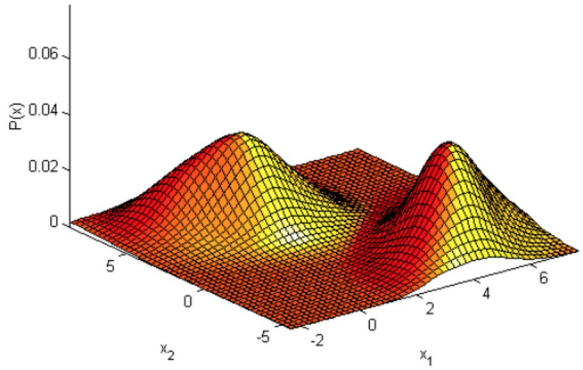

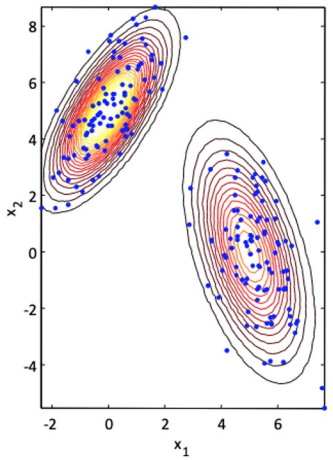

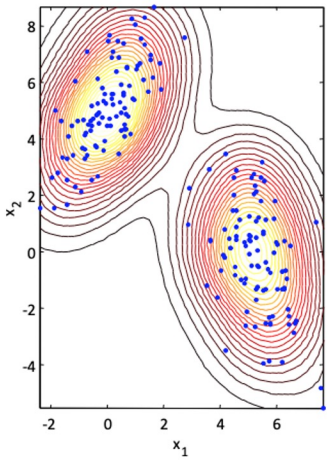

$h = 1.06\sigma N^{-1/5}$

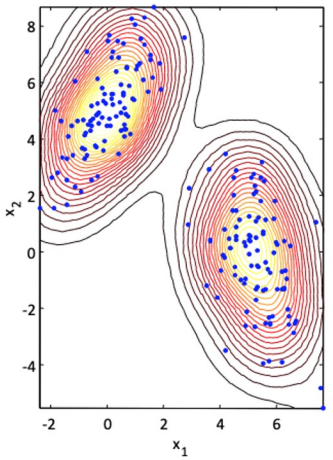

$h = 0.9AN^{-1/5}$

Métodos de Estimação de Densidades

- **Gaussian Mixture Model (GMM)**
  - Assume-se que todos os dados são gerados a partir de distribuições gaussianas com parâmetros desconhecidos.
  - O modelo resultante é a composição (soma) de um conjunto de M FDP normais ponderadas. Cada FDP tem média e variância (covariância) específica.

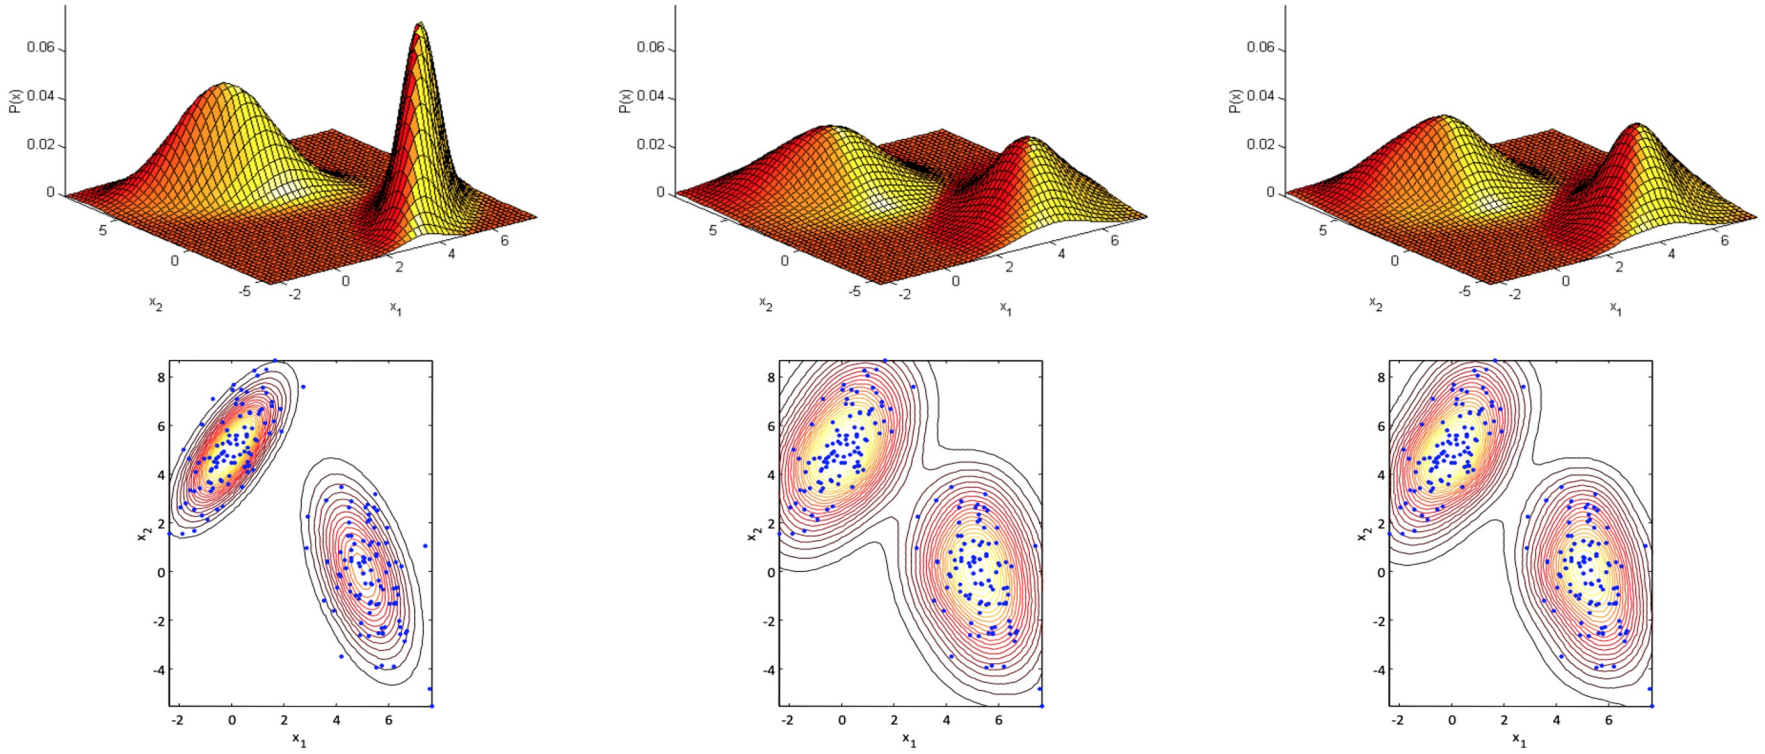

Métodos de Estimação de Densidades

- Gaussian Mixture Model (GMM)
  - Caso univariado

$$p(x) = \sum_{i=1}^{M} w_i f(x; \mu_i, \sigma_i)$$

$$f(x; \mu_i, \sigma_i) = \frac{1}{\sqrt{2\pi}\sigma_i} e^{-\frac{(x-\mu_i)^2}{\sigma_i^2}}$$

$$\sum_{i=1}^{M} w_i = 1$$

Métodos de Estimação de Densidades

- Gaussian Mixture Model (GMM)
  - Caso multivariado

$$p(\boldsymbol{x}) = \sum_{i=1}^{M} w_i f(\boldsymbol{x}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$$

$$f(\boldsymbol{x}; \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) = \frac{1}{\sqrt{(2\pi)^N |\boldsymbol{\Sigma}_i|^{\frac{1}{2}}}} e^{-(\boldsymbol{x}-\boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1} (\boldsymbol{x}-\boldsymbol{\mu}_i)}$$

$$\sum_{i=1}^{M} w_i = 1$$

Métodos de Estimação de Densidades

- Gaussian Mixture Model (GMM) - Exemplo
  - Caso com 2 gaussianas.
  - E se conhece as fontes das duas distribuições

Basta obter as médias e variâncias para distribuição

$$\mu_b = \frac{x_1 + x_2 + \ldots + x_{n_b}}{n_b}$$

$$\sigma_b^2 = \frac{(x_1 - \mu_1)^2 + \ldots + (x_n - \mu_n)^2}{n_b}$$

$$p(x) = \sum_{i=1}^{M} w_i f(x; \mu_i, \sigma_i)$$

Métodos de Estimação de Densidades

- Gaussian Mixture Model (GMM) - Exemplo
  - Caso com 2 gaussianas.
  - E se as fontes não são conhecidas?
    - Necessita-se de (μ_a, σ_a) e (μ_b, σ_b) para decidir a fonte.
    - Necessita-se conhecer as fontes para se estimar (μ_a, σ_a) e (μ_b, σ_b).

$$P(b \mid x_i) = \frac{P(x_i \mid b)P(b)}{P(x_i \mid b)P(b) + P(x_i \mid a)P(a)}$$

$$P(x_i \mid b) = \frac{1}{\sqrt{2\pi\sigma_b^2}} \exp\left(-\frac{(x_i - \mu_b)^2}{2\sigma_b^2}\right)$$

Métodos de Estimação de Densidades

- Algoritmo EM (*Expectation Maximization*)
  - Há k gaussianas (g_1, ..., g_k) e n pontos (x_1, ..., x_n).
  - Inicia-se os parâmetros das k gaussianas (μ_i, σ_i) aleatoriamente.
  - Para cada ponto x_j, obtém-se $P(gi/x_j)$
    - Probabilidade de pertencer a g_i. (ETAPA Expectation)
  - Para cada gaussiana i,
    - Adapte os seus parâmetros (μ_i, σ_i) para se ajustar aos pontos atribuídos a ela. (ETAPA Maximization)
  - Repita as etapas E e M até convergir.

$$P(b \mid x_i) = \frac{P(x_i \mid b)P(b)}{P(x_i \mid b)P(b) + P(x_i \mid a)P(a)}$$

$$P(x_i \mid b) = \frac{1}{\sqrt{2\pi\sigma_b^2}} \exp\left(-\frac{(x_i - \mu_b)^2}{2\sigma_b^2}\right)$$

Métodos de Estimação de Densidades

- Algoritmo EM (Expectation Maximization)

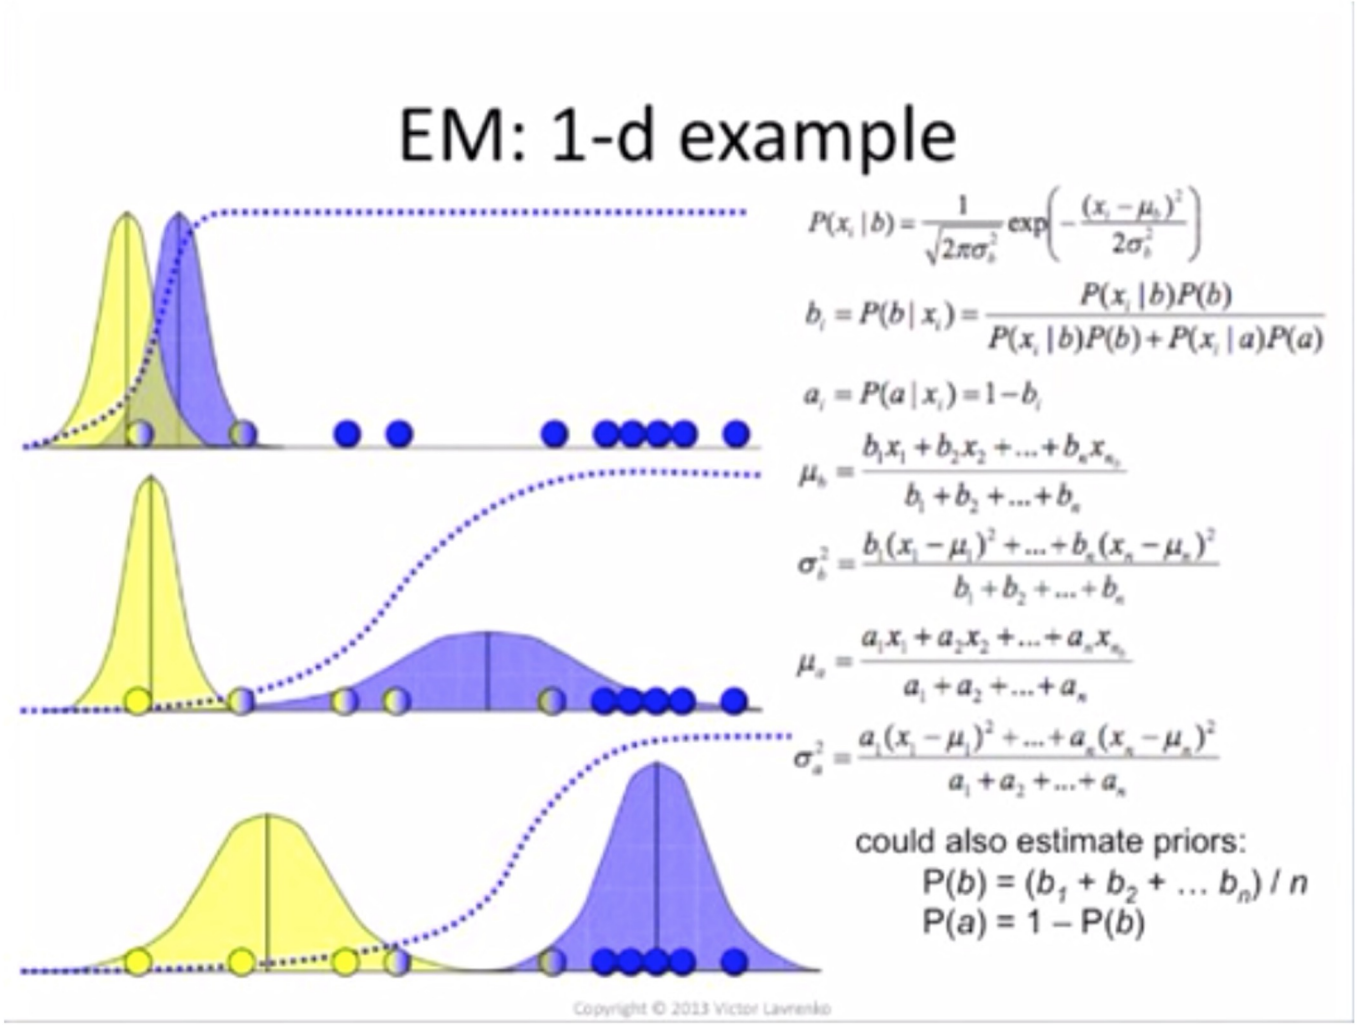

https://www.youtube.com/watch?v=l1W3BvjJnmY

Métodos de Estimação de Densidades

- Algoritmo EM (Expectation Maximization)
  - Caso Bidimensional

$$\mathcal{N}(\underline{x}\ ;\ \underline{\mu}, \Sigma) = \frac{1}{(2\pi)^{d/2}} |\Sigma|^{-1/2} \exp\left\{ -\frac{1}{2} (\underline{x} - \underline{\mu})^T \Sigma^{-1} (\underline{x} - \underline{\mu}) \right\}$$

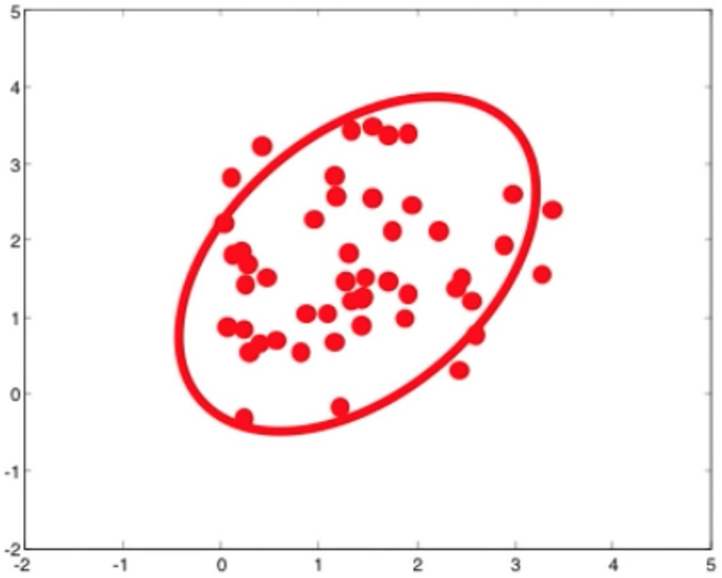

Σ é matriz de covariâncias

Métodos de Estimação de Densidades

- Algoritmo EM (Expectation Maximization)
  - Caso Bidimensional

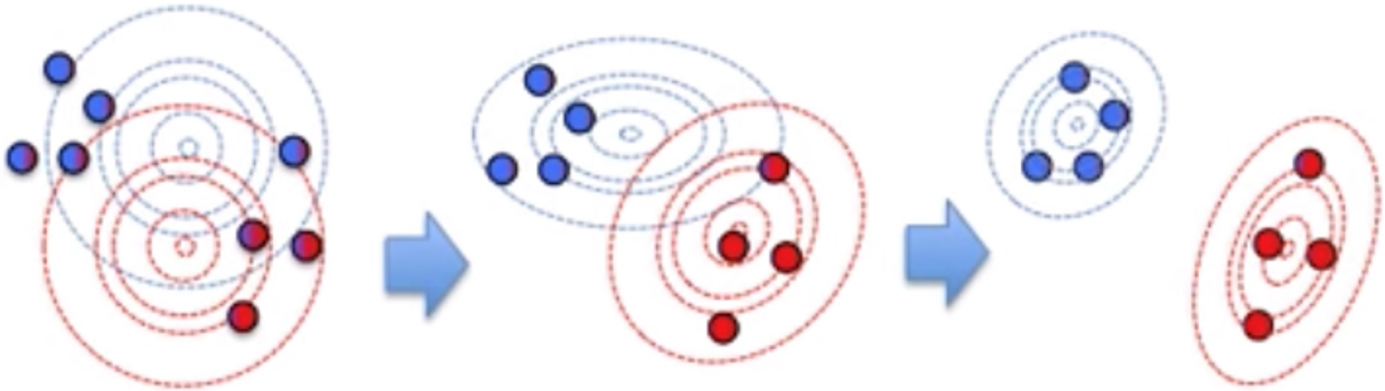

"That's all Folks!"